

Bachelor Thesis (173312)
Angewandte Informatik (SPO1a)

GraphQL und REST im Kontext relationaler und graphbasierter Datenbanken hinsichtlich Latenz bei unterschiedlichen Anfragekomplexitäten

Robin Hefner*

21. Januar 2025

Eingereicht bei Prof. Dr. Fankhauser

*206488, rohefner@stud.hs-heilbronn.de

Inhaltsverzeichnis

Abkürzungsverzeichnis	IV
Abbildungsverzeichnis	V
Abstract	VII
Zusammenfassung	VIII
1 Einleitung	1
1.1 Motivation	1
1.2 Forschungsfragen	2
1.3 Ziel der Arbeit	2
1.4 Vorgehensweise	3
2 Grundlagen	4
2.1 Relationale Algebra	4
2.1.1 Basisrelation	4
2.1.2 Grundoperationen	4
2.2 Graphentheorie	5
2.2.1 Knoten	6
2.2.2 Kanten	6
2.2.3 Traversierung	7
2.3 APIs	7
2.3.1 Definition	7
2.3.2 REST API	8
2.3.3 GraphQL	8
2.4 Datenbank	9
2.4.1 Definition von Datenbank und Datenbank-Management-System . . .	9
2.4.2 Relationale Datenbank	9
2.4.3 Graphdatenbanken	10
3 Literaturanalyse	12
3.1 Latenzzeit von GraphQL und REST bei unterschiedlichen Anfragenkomplexitäten	12
3.2 Latenz von REST- und GraphQL-APIs bei Graph- und relationalen Datenbanken	14
4 Datenmodellierung	18
5 Systemdesign	19
5.1 Datenbankdesign	19
5.1.1 Relationales Datenbankdesign	19
5.1.2 Graphdatenbankdesign	21
5.2 Schnittstellendesign	22
5.2.1 REST	22
5.2.2 GraphQL	26

5.3	Testumgebung	29
6	Implementierung	30
6.1	Grundprinzipien	30
6.2	Post-REST	31
6.3	Post-Graph	32
6.4	Neo4REST	33
6.5	Neo4Graph	34
6.6	API-Response-Test	35
7	Ergebnisse	36
8	Diskussion	45
9	Ausblick	47
10	Fazit	48
	Literaturverzeichnis	49
	Eidesstattliche Erklärung	52
	Appendix	53

Abkürzungsverzeichnis

API: Application Programming Interface

DBMS: Database Management System

DI: Dependency Injection

HTTP: Hypertext Transfer Protocol

RDBMS: relationales Datenbankmanagementsystem

REST: Representational State Transfer

SQL: Structured Query Language

Abbildungsverzeichnis

2.1	Modell eines ungerichteten Graphen. [17]	5
2.2	Modell eines gerichteten (a) und eines gewichteten Graphen (b). [17]	7
3.1	Latenz bei GraphQL vs. REST [20]	13
3.2	Datenmenge weltweit [5]	15
3.3	Informationsverbundenheit [19]	15
3.4	Ergebnisse der Abfragen durch Integer in Millisekunden [22]	16
3.5	Ergebnisse Abfragen durch Character in Millisekunden [22]	17
4.1	Klassendiagramm	18
5.1	Datenbankdiagramm	19
5.2	Tupel der Tabelle ‚Person‘	20
5.3	Tupel der Tabelle ‚Person_Issue‘	20
5.4	Tupel der Tabelle ‚Issue‘	20
5.5	Tupel der Tabelle ‚Person_Project‘	20
5.6	Tupel der Tabelle ‚Project‘	20
5.7	Graphdiagramm	21
5.8	‚GET api/issues?counter=x&?joins=y‘-Response	22
5.9	‚GET api/persons/:pid‘-Response	22
5.10	‚GET api/persons‘-Response	23
5.11	‚GET api/persons/:pid/projects/issue‘-Response	24
5.12	‚POST api/persons/:pid/projects/:pid/issues‘-Body	24
5.13	‚POST api/persons/:pid/projects/:pid/issues‘-Response	25
5.14	GraphQL-Query GET api/issues?counter=x&?joins=y	26
5.15	GraphQL-Query-Äquivalent zu GET api/persons/:pid	26
5.16	GraphQL-Query-Äquivalent zu GET api/persons	27
5.17	GraphQL-Query-Äquivalent zu GET api/persons/:pid/projects/issue	27
5.18	GraphQL-Query-Äquivalent zu POST api/persons/:pid/projects/:pid/issues	28
6.1	PostREST-Java-Klassen	31
6.2	Typ aus der schema.graphqls-Datei	32
6.3	Query aus der schema.graphqls-Datei	32
6.4	Mutation aus der schema.graphqls-Datei	32
6.5	PostGraph-Java-Klassen	33
6.6	Neo4REST-Java-Klassen	34
6.7	Neo4Graph-Java-Klassen	34
6.8	Java Klassen Neo4Graph	35
7.1	HEAD /api/resource	36
7.2	PostREST parametrisierte Abfragen	37
7.3	PostGraph parametrisierte Abfragen	38
7.4	Neo4REST parametrisierte Abfragen	39
7.5	Neo4Graph parametrisierte Abfragen	40
7.6	GET /api/persons/:pid	41
7.7	GET /api/persons	42

7.8	GET /api/persons/:pid/projects/issues	43
7.9	POST /api/persons/:pid/projects/:prid/issues	44

Abstract

This thesis analyses the performance of GraphQL and REST in the context of relational and graph-based databases in terms of latency for different query complexities. The aim of the analysis was to evaluate the advantages and disadvantages of both API technologies and to analyse the interactions with the underlying database architectures.

According to the results, GraphQL offers clear advantages for complex queries because client-driven data queries reduce the number of API calls. For bulk queries with large amounts of data, REST achieves faster response times, while GraphQL is superior for hierarchical and flexible queries. In terms of database technologies, relational databases proved to be more efficient with structured data and low branching, while graph databases are more powerful due to their traversal mechanisms, especially with highly networked data and high query complexity.

The combination of GraphQL and graph databases showed a significant reduction in latency in complex scenarios, with GraphQL also achieving lower latencies for simpler queries with a relational database than a comparable REST API. The findings provide practical information for selecting the optimal API and database technology and offer guidance for the development of high-performance and scalable systems.

Keywords: REST, GraphQL, API, relational database, graph database

Zusammenfassung

Die vorliegende Arbeit untersucht die Performance von GraphQL und REST im Kontext relationaler und graphbasierter Datenbanken hinsichtlich der Latenz bei unterschiedlichen Anfragekomplexitäten. Ziel der Analyse war es, die Vor- und Nachteile beider API-Technologien zu bewerten sowie die Wechselwirkungen mit den zugrunde liegenden Datenbankarchitekturen zu analysieren.

Gemäß den Ergebnissen bietet GraphQL bei komplexen Abfragen deutliche Vorteile, weil clientgesteuerte Datenabfragen die Anzahl der API-Aufrufe reduzieren. Bei Bulk-Abfragen mit großen Datenmengen erzielt REST schnellere Antwortzeiten, während GraphQL bei hierarchischen und flexiblen Abfragen überlegen ist. Hinsichtlich der Datenbanktechnologien erwiesen sich relationale Datenbanken als effizienter bei strukturierten Daten und geringen Verzweigungen, während Graphdatenbanken durch ihre Traversal-Mechanismen besonders bei stark vernetzten Daten und hohen Abfragekomplexitäten leistungstärker sind.

Die Kombination aus GraphQL und Graphdatenbanken zeigte eine signifikante Reduzierung der Latenz bei komplexen Szenarien, wobei GraphQL bei einfacheren Anfragen ebenfalls mit einer relationalen Datenbank niedrigere Latenzen erzielte als eine vergleichbare REST-API. Die gewonnenen Erkenntnisse liefern praxisrelevante Hinweise für die Auswahl der optimalen API- sowie Datenbanktechnologie und bieten Orientierungshilfen für die Entwicklung leistungstarker und skalierbarer Systeme.

Stichwörter: REST, GraphQL, API, relationale Datenbank, Graphdatenbank

1 Einleitung

1.1 Motivation

In der modernen Softwareentwicklung sind Application Programming Interfaces (APIs) zentral für die Verbindung und den Austausch zwischen verschiedenen Diensten und Anwendungen. Traditionell stellt der Representational State Transfer (REST) die bevorzugte Methode zur Erstellung von APIs dar, doch mit der Einführung von GraphQL, einer von Facebook entwickelten Abfragesprache, bietet sich Entwicklern eine weitere Option, die zunehmend an Bedeutung gewinnt.

Die Wahl der passenden API-Architektur hängt eng mit der eingesetzten Datenbanktechnologie zusammen, weil diese die Effizienz und Flexibilität der Anwendung stark beeinflusst. Relationale Datenbanken, die auf strukturierten Tabellen basieren, gelten als etabliert und ermöglichen präzise Datenabfragen mit hoher Zuverlässigkeit, wobei sie in Kombination mit REST eine klare und stabile Struktur für den Zugriff auf Daten bieten. GraphQL hingegen erlaubt die gezielte Abfrage der benötigten Daten, was besonders bei komplexen Modellen vorteilhaft sein kann.

Für Anwendungen, die intensiv mit vernetzten Daten arbeiten, stellen Graphdatenbanken eine ideale Basis dar. In Verbindung mit GraphQL lassen sich komplexe Abfragen effizient umsetzen, weil die Technologie auf die Eigenschaften solcher Datenbanken abgestimmt ist. Auch mit REST können Graphdatenbanken genutzt werden, allerdings ist hier oft zusätzlicher Aufwand nötig, um die Daten in eine geeignete Form zu bringen.

Die Entscheidung zwischen REST und GraphQL sowie für die passende Datenbanktechnologie hat weitreichende Konsequenzen für die Entwicklung und den Betrieb einer Anwendung. Unternehmen sollten daher genau prüfen, welche Kombination aus API-Ansatz und Datenbank ihren Anforderungen entspricht, sei es in Bezug auf Leistung, Skalierbarkeit oder Flexibilität.

1.2 Forschungsfragen

Nachfolgend werden die Forschungsfragen vorgestellt, die sich aus der Motivation ableiten und als Grundlage der Forschung dieser Arbeit dienen.

Die übergeordnete Forschungsfrage lautet: Wie wirkt sich die Wahl der API-Architektur und der zugrunde liegenden Datenbanktechnologie auf die Latenzzeiten bei Anfragen unterschiedlicher Komplexität aus?

Diese wurde in die nachfolgenden Forschungsfragen FF1 und FF2 unterteilt, die gesondert beantwortet werden und somit die übergeordnete Forschungsfrage beantworten.

- **FF1: Wie unterscheiden sich GraphQL und REST hinsichtlich der Latenzzeit bei unterschiedlichen Anfragenkomplexitäten?** Diese Frage zielt darauf ab, die Performance beider Systeme unter variablen Bedingungen zu vergleichen. Beispielsweise wird untersucht, wie schnell eine API auf eine einfache Datenabfrage reagiert, im Vergleich zu einer komplexeren Abfrage, die mehrere Abhängigkeiten involviert. Diese Ermittlung soll Einblicke in die Effizienz der beiden Technologien bieten und somit als Entscheidungshilfe für Entwickler dienen, um die optimale Lösung für ihre spezifischen Bedürfnisse auszuwählen.
- **FF2: Wie beeinflussen Graph- und relationale Datenbanken die Latenz von REST- und GraphQL-APIs?** Hierbei wird der Einfluss der zugrunde liegenden Datenbanktechnologien auf die Latenzzeiten von API-Anfragen untersucht, wobei speziell betrachtet wird, wie sich die Wahl einer graphbasierten Datenbank im Vergleich zu einer relationalen Datenbank auf die Antwortzeiten der APIs auswirkt. Ziel ist es, herauszufinden, wie verschiedene Datenbankmodelle die Effizienz der API-Interaktionen beeinflussen und welche Datenbanktechnologie die niedrigsten Latenzwerte für unterschiedliche Anwendungsfälle bietet.

1.3 Ziel der Arbeit

Das Ziel dieser Arbeit besteht darin, die Leistungsfähigkeit und Effizienz von REST- sowie GraphQL-APIs im Zusammenspiel mit relationalen und graphbasierten Datenbanken zu untersuchen sowie miteinander zu vergleichen. Im Mittelpunkt steht dabei die Analyse, wie sich die Wahl der API-Architektur und der zugrunde liegenden Datenbanktechnologie auf die Latenzzeiten und die Effizienz bei Anfragen unterschiedlicher Komplexität auswirkt. Es soll aufgezeigt werden, welche Wechselwirkungen zwischen API-Architektur sowie Datenbanktechnologie bestehen und wie diese die Leistungsfähigkeit moderner API-Systeme beeinflussen. Auf Basis der definierten Forschungsfragen wird eine Analyse durchgeführt, die praxisrelevante Einsichten für die Implementierung effizienter API-Systeme liefert.

1.4 Vorgehensweise

Das Ziel dieser Arbeit besteht darin, die Leistungsfähigkeit und Effizienz von REST- sowie GraphQL-APIs im Zusammenspiel mit relationalen und graphbasierten Datenbanken zu untersuchen sowie miteinander zu vergleichen. Es soll aufgezeigt werden, welche Wechselwirkungen zwischen API-Architektur sowie Datenbanktechnologie bestehen und wie diese die Leistungsfähigkeit moderner API-Systeme beeinflussen. Auf Basis der definierten Forschungsfragen wird eine Analyse durchgeführt, die mithilfe von Studien und anderen Arbeiten deren Beantwortung unterstützt. Außerdem wird ein umfassendes Experiment durchgeführt, bei dem die API-Typen mit den Datenbanktechnologien implementiert und auf ihre Latenz bei unterschiedlichen Anfragen getestet werden. Im Mittelpunkt steht dabei die Analyse, wie sich die Wahl der API-Architektur und der zugrunde liegenden Datenbanktechnologie auf die Latenzzeiten und die Effizienz bei Anfragen unterschiedlicher Komplexität auswirkt.

2 Grundlagen

Das vorliegende Kapitel vermittelt die theoretischen Grundlagen für das Verständnis dieser Arbeit. Dabei umfassen die hier beschriebenen Konzepte relationale Algebra, Graphentheorie, APIs sowie relationale und Graphdatenbanken.

2.1 Relationale Algebra

Die relationale Algebra beschreibt ein mathematisches System, das 1970 von E. F. Codd entwickelt wurde und unter anderem zur Abfrage sowie Mutation von Daten in relationalen Datenbanken verwendet wird. Durch die relationale Algebra wird eine Menge an Operationen beschrieben, die auf Relationen angewendet werden können, um neue Relationen zu bilden. [3]

2.1.1 Basisrelation

Die Anwendung relationaler Algebra erfordert die Verwendung von Basisrelationen als fundamentale Bausteine, um mittels Grundoperationen komplexe Ausdrücke zu konstruieren, die neue Relationen definieren. Eine Basisrelation setzt sich aus drei Komponenten zusammen: Tupel, Attributen und Domänen. Tupel reflektieren die Zeilen einer Tabelle, die die einzelnen Datensätze repräsentieren. Diese werden durch Attribute in spezifische Spalten eingeteilt, worin die Eigenschaften der Tupel beschrieben sind. Die für die einzelnen Attribute zulässigen Wertebereiche werden als Domänen bezeichnet. Demnach entspricht jede Relation einer Menge von Tupeln mit spezifischen Attributen sowie deren Domänen. [18]

2.1.2 Grundoperationen

Grundoperationen in der relationalen Algebra beschreiben einfache mengentheoretische Operationen, die auf die Basisrelationen angewandt werden. Insgesamt existieren sechs Grundoperationen, die nachfolgend erläutert werden.

- Bei der **Selektion** σ werden die einzelnen Tupel basierend auf einer Bedingung gefiltert, beispielsweise $\sigma \text{ Alter} > 30 (\text{Person})$. Hierdurch werden nur Personen mit einem Alter von über 30 Jahren zurückgeliefert.
- Die **Projektion** π ermöglicht die Auswahl oder Entfernung bestimmter Attribute einer Relation. Beispielsweise werden durch $\pi \text{ Name, Alter} (\text{Person})$ nur der Name und das Alter einer Person zurückgegeben.

- Das **Kartesische Produkt** \times kombiniert jede Zeile der ersten mit jeder Zeile der zweiten Relation, womit $R \times S$ alle möglichen Kombinationen aus R und S erzeugt.
- Eine **Vereinigung** \cup verknüpft die Tupel zweier Relationen, die dieselbe Struktur aufweisen. $R \cup S$ kombiniert somit alle Tupel aus beiden Relationen mit identischer Struktur, ohne Duplikate zu erzeugen.
- Weiter liefert die **Differenz** \setminus zweier Relationen alle Tupel, die in der ersten Relation vorkommen, aber nicht in der zweiten. Somit gibt $R \setminus S$ alle Tupel R aus, die nicht in S enthalten sind.
- Der **Schnitt** \cap nennt die Tupel, die in beiden Relationen vorhanden sind. Somit gibt $R \cap S$ die Tupel zurück, die sowohl in R als auch in S enthalten sind.

Durch die Verbindung dieser Grundoperationen können andere Operationen erstellt werden, beispielsweise ein Theta-Join \bowtie , der durch eine Kombination aus kartesischem Produkt und Selektion alle Tupel zweier Relationen aufgrund einer Bedingung zusammenlegt. [18]

2.2 Graphentheorie

Ein Graph besteht im Allgemeinen aus Knoten und verbindenden Kanten (vgl. Abb 2.1). In der Informatik bietet diese Datenstruktur einen deutlichen Vorteil gegenüber der relationalen Algebra, wenn stark verzweigte Daten vorliegen. [17]




Abbildung 2.1: Modell eines ungerichteten Graphen. [17]

2.2.1 Knoten

Knoten beschreiben Punkte innerhalb eines Graphen, die beispielsweise als Objekte der realen Welt verstanden werden können. Sie können zum Beispiel als geografische Koordinaten dienen, um einen Distanzgraphen zu erstellen, oder als Webseiten, um einen Webgraphen zu erhalten, der die Verbindung verschiedener Webseiten aufzeigt. Innerhalb der Knoten werden verschiedene Typen unterschieden: Zum einen existieren isolierte Knoten ohne Verbindung zu anderen Knoten des Graphen, die zur Identifizierung nicht verbundener Teile eines Netzwerks verwendet werden können. Zum anderen bestehen verbundene Knoten, die mindestens eine Verbindung zu einem anderen benachbarten Knoten aufweisen. Außerdem kann eine indirekte Verbindung entstehen, indem ein Pfad zwischen Ausgangs- und Endknoten existiert, der über mehrere Verbindungen führt. [17] [2]

2.2.2 Kanten

Kanten dienen in einem Graphen dazu, Knoten miteinander zu verbinden, um eine Relation zwischen ihnen zu visualisieren. Jede Kante besitzt einen Start- und Endknoten, wobei es sich um denselben Knoten handeln kann; in diesem Fall liegt eine Schleife vor. Ebenso wie es verschiedene Arten von Knoten gibt, existieren auch verschiedene Kanten. In Abb. 2.1 sind *ungerichtete Kanten* im Graphen zu sehen, Sie die die Knoten auf die trivialste Art verbinden, indem sie ohne Richtung, Gewicht oder andere Beschränkung eine Verbindung herstellen. Durch ungerichtete Kanten entsteht ein ungerichteter Graph. *Gerichtete Kanten* werden in Abb. 2.2 (a) durch einen Pfeil visualisiert, der angibt, in welche Richtung der Graph eine Beziehung zwischen den Knoten herstellt. Es ist ebenfalls möglich, dass zwei Knoten eine beidseitige Beziehung durch zwei gerichtete Kanten eingehen, also eine Kante pro Richtung. Ein Graph, der durch gerichtete Kanten verbunden ist, wird ‚gerichteter Graph‘ genannt. Werden Zahlenwerte zu einer Kante hinzugefügt (vgl. Abb 2 (b)), so handelt es sich um eine *gewichtete Kante*. Sie können verwendet werden, um die Strecke zwischen zwei Kanten darzustellen oder die Kosten für die Nutzung der Kante anzugeben. Wird ein Graph mit gewichteten Kanten verbunden, liegt ein gewichteter Graph vor. [17] [2]




Abbildung 2.2: Modell eines gerichteten (a) und eines gewichteten Graphen (b). [17]

2.2.3 Traversierung

Die Bewegung eines Knoten oder einer Kante zu einem anderen Knoten innerhalb eines Graphen nach vorgegebenen Kriterien wird als Traversierung bezeichnet. Graphdatenbanken bieten in der Regel Traversierungsmechanismen, um Daten miteinander verbundener Knoten effizient abzufragen sowie abzurufen. [15]

2.3 APIs

Nachfolgend werden die Grundlagen von APIs erläutert, wobei die grundlegenden Definitionen sowie die für diese Arbeit relevanten Typen behandelt werden.

2.3.1 Definition

Eine API bezeichnet eine Schnittstelle, die Entwicklern den Zugriff auf Daten und Informationen ermöglicht. Beispiele für häufig genutzte APIs bieten die Twitter- und Facebook-APIs, die für Entwickler zugänglich sind und die Interaktion mit der Software von Twitter sowie Facebook ermöglichen. Zudem erlauben APIs die Kommunikation zwischen Anwendungen und bieten diesen einen Weg, miteinander über ein Netzwerk, überwiegend das Internet, in einer gemeinsamen Sprache zu kommunizieren. [11]

2.3.2 REST API

REST wurde erstmals im Jahr 2000 in einer Dissertation von Roy Fielding beschrieben, wobei es sich um einen Software-Architekturstil für APIs handelt. Dabei basiert REST auf dem ressourcenorientierten Designprinzip, wonach jede Entität als Ressource betrachtet und durch einen eindeutigen Uniform Resource Locator identifiziert wird. Die Architektur fundiert auf sechs grundlegenden Beschränkungen, der Client-Server-Architektur, der Zustandslosigkeit, dem Caching, der einheitlichen Schnittstelle, dem Mehrschichtigen Systemmodell sowie dem Code on Demand. Die Client-Server-Architektur beschreibt, dass der Client und Server unabhängig voneinander agieren. Einen wesentlichen Bestandteil von REST bildet die Zustandslosigkeit, d. h., jede Anfrage beinhaltet sämtliche für die Verarbeitung erforderlichen Informationen, was die Interaktion zwischen Client und Server vereinfacht. Die Umsetzung der Operationen Create, Read, Update und Delete (CRUD) erfolgt durch die HTTP-Methoden (POST, GET, PUT, DELETE). Das in HTTP integrierte Caching nutzt REST, um die Antwortzeiten und die Leistung zu optimieren, wobei die Möglichkeit besteht, Serverantworten als cachefähig oder nicht cachefähig zu kennzeichnen. Des Weiteren ist eine einheitliche Schnittstelle zu nennen, die die Interaktionen zwischen unterschiedlichen Geräten und Anwendungen erleichtert, worüber hinaus REST ein mehrschichtiges System erfordert, bei dem jede Komponente lediglich mit der unmittelbar vorgelagerten Schicht interagiert. Code on Demand ist die letzte Einschränkung und besagt, dass Ressourcen bei der Antwort auf Anfragen darauf vorbereitet sind, Code bereitzustellen der auf dem Client und nicht auf dem Server ausgeführt wird. Diesen Prinzipien folgende RESTful-APIs, nutzen HTTP-Anfragen, um Ressourcen effizient zu bearbeiten. [6] [20]

2.3.3 GraphQL

GraphQL wurde 2012 von Facebook für den internen Gebrauch entwickelt und 2015 als Open-Source-Projekt veröffentlicht. Das Kernkonzept von GraphQL basiert auf clientgetriebenen Abfragen, bei denen der Client die Struktur der Daten präzise definiert und nur die tatsächlich benötigten Daten anfordert. Diese clientseitige Steuerung reduziert die Menge der übertragenen Daten und führt zu effizienteren Netzwerkaufrufen, weil nur die relevanten Informationen übermittelt werden. Im Vergleich zu REST verursacht GraphQL signifikant weniger Overhead, was die Netzwerkperformance optimiert. Die hierarchische Struktur der Abfragen, die die Graphstruktur widerspiegelt, ermöglicht eine intuitive und flexible Datenmodellierung, wobei die starke Typisierung in GraphQL durch ein Schema definiert wird, das die Typen der Daten spezifiziert, was eine effizientere Validierung der Abfragen und eine klarere Dokumentation erlaubt. Im Gegensatz zu REST, der für verschiedene Operationen mehrere Endpunkte erfordert, nutzt GraphQL nur einen Endpunkt für alle API-Abfragen, was die Komplexität auf der Serverseite reduziert und eine vereinfachte API-Verwaltung ermöglicht. [20]

2.4 Datenbank

Im Folgenden werden die Grundlagen von Datenbanken behandelt, indem zentrale Definitionen im Zusammenhang mit Datenbanken und die verschiedenen Arten von Datenbanken vorgestellt werden.

2.4.1 Definition von Datenbank und Datenbank-Management-System

Eine Datenbank stellt eine Sammlung von Daten und Informationen dar, die für den einfachen Zugriff gespeichert und organisiert werden, was sowohl die Verwaltung als auch die Aktualisierung der Daten umfasst. Die in der Datenbank gespeicherten Inhalte können nach Bedarf erweitert, gelöscht oder geändert werden. Dabei basiert die Funktionsweise von Datenbanksystemen auf der Abfrage von Informationen oder Daten, woraufhin entsprechende Anwendungen ausgeführt werden. Hier bezeichnet ‚Datenbank-Management-System‘ (DBMS) eine Systemsoftware, die für die Erstellung und Verwaltung von Datenbanken eingesetzt wird. Zu den Funktionalitäten zählen die Erstellung von Berichten, die Kontrolle von Lese- und Schreibvorgängen sowie die Durchführung einer Nutzungsanalyse. Das DBMS fungiert als Schnittstelle zwischen den Endnutzern und der Datenbank, um die Organisation und Manipulation von Daten zu erleichtern, wobei die Kernfunktionen des DBMS die Verwaltung von Daten, des Datenbankschemas, das die logische Struktur der Datenbank definiert, sowie der Datenbank-Engine umfassen, die das Abrufen, Aktualisieren und Sperren von Daten ermöglicht. Diese drei wesentlichen Elemente dienen der Bereitstellung standardisierter Verwaltungsverfahren, der Gleichzeitigkeit, der Wiederherstellung, der Sicherheit und der Datenintegrität. [9]

2.4.2 Relationale Datenbank

Relationale Datenbanken basieren auf dem von E. F. Codd entwickelten relationalen Modell und fundieren auf relationaler Algebra sowie dem Tupel-Relational-Kalkül. Sie speichern Daten in einer hochstrukturierten Tabellenform, wobei jede Tabelle aus Zeilen, den sogenannten Tupeln, und Spalten, den sogenannten Attributen, besteht. Jede Zeile repräsentiert einen Datensatz, während jede Spalte durch einen spezifischen Datentyp definiert ist. Diese Struktur ermöglicht eine klare Organisation der Daten und erleichtert deren Verwaltung. Relationale Datenbanken verwenden Primär- und Fremdschlüssel, um Beziehungen zwischen Tabellen herzustellen sowie referenzielle Integrität zu gewährleisten, wodurch die Datenkonsistenz erhalten bleibt. Aufgrund dieser Eigenschaften werden die Tabellen auch als ‚Relationen‘ bezeichnet.

Die bekanntesten relationalen Datenbank Management Systeme (RDBMS) sind Microsoft SQL Server, Oracle MySQL und IBM DB2. Ein RDBMS organisiert alle Daten in tabellarischer Form und bietet Funktionen wie Primärschlüssel zur eindeutigen Identifikation von Datensätzen sowie Indizes, die die Geschwindigkeit der Datenabfragen erhöhen. Darüber hinaus unterstützen RDBMS die Erstellung virtueller Tabellen, die komplexe Abfragen vereinfachen, sowie einen kontrollierten Mehrbenutzerzugriff mit individueller Rechtevergabe. Die Verwendung einer standardisierten SQL ermöglicht die Verwaltung, Abfrage und Manipulation von Daten, wobei die genannten Merkmale die Flexibilität und Benutzerfreundlichkeit relationaler Datenbanken stärken. Ein Vorteil relationaler Datenbanken liegt in ihrer Unterstützung der Prinzipien Atomicity, Consistency, Isolation und Durability (ACID), die Stabilität und Sicherheit bei Transaktionen gewährleisten, was sie für mehrere Anwendungsbereiche geeignet macht. Darüber hinaus bieten sie eine hohe Datenintegrität, reduzieren Redundanz und ermöglichen die einfache Implementierung von Sicherheitsmaßnahmen. Trotz dieser Vorteile stoßen relationale Datenbanken bei bestimmten Anforderungen an ihre Grenzen: Sie sind selten für hohe Skalierbarkeit geeignet und können mit dem exponentiellen Wachstum von Daten schwer umgehen. Auch die Einrichtung und Wartung solcher Systeme erweist sich häufig als kostspielig und die Verwaltung unstrukturierter Daten wie Multimedia oder Social-Media-Inhalten stellt eine Herausforderung dar. Zudem erschwert die tabellarische Struktur komplexe Datenverknüpfungen und die Integration mehrerer Datenbanken. Aufgrund dieser Einschränkungen führten moderne Anwendungen und Big-Data-Anforderungen zur Entwicklung von NoSQL-Datenbanken, die effektiver auf die Verwaltung unstrukturierter und verteilter Daten ausgelegt sind. Dennoch bleiben relationale Datenbanken aufgrund ihrer Standardisierung, Benutzerfreundlichkeit und ihrer breiten Einsatzmöglichkeiten ein wesentlicher Bestandteil der Datenbanktechnologie. [7] [9]

2.4.3 Graphdatenbanken

Graphdatenbanken beschreiben spezialisierte Datenbanksysteme, die dem User ein Datenmodell in Form eines Graphen präsentieren. Darüber hinaus enthalten die Graphen Informationen über die Eigenschaften der Knoten und Kanten, was eine flexible und schemafreie Speicherung semistrukturierter Daten ermöglicht. Abfragen in Graphdatenbanken werden häufig als Traversal formuliert, wodurch sie gegenüber relationalen Datenbanken erhebliche Geschwindigkeitsvorteile bieten, insbesondere bei komplexen Beziehungsabfragen. Es wird zwischen nativen und nicht nativen Graphdatenbanken unterschieden, wobei native Graphdatenbanken speziell für das Graphmodell entwickelt sind und die Daten intern in Graphenform speichern. Nicht native Graphdatenbanken hingegen verwenden andere Speichertechnologien, beispielsweise relationale Datenbanken, und präsentieren die Daten lediglich in Form von Graphen, um CRUD-Zugriffe zu ermöglichen. Beide Typen gehören zur Kategorie der NoSQL-Datenbanken, die durch den Verzicht auf das starre Tabellenschema

relationaler Datenbanken deren Schwächen umgehen. Durch ihre besondere Architektur ermöglichen Graphdatenbanken nicht nur eine effiziente Verarbeitung von Beziehungsdaten, sondern erfüllen auch ACID-Bedingungen und unterstützen Rollbacks, was die Konsistenz der gespeicherten Informationen gewährleistet. Damit stellen sie eine leistungsstarke Alternative zu traditionellen relationalen Datenbanken dar, insbesondere in Anwendungsbereichen mit hochgradig verknüpften Daten. [9] [16]

3 Literaturanalyse

In diesem Kapitel werden die in der Einleitung definierten Forschungsfragen untersucht, wofür eine Literaturanalyse erfolgt, die bestehende Studien, Bücher und wissenschaftliche Artikel betrachtet. Ziel ist es, aus der vorhandenen Literatur systematisch Erkenntnisse abzuleiten, die die Performance in verschiedenen Szenarien beleuchten.

3.1 Latenzzeit von GraphQL und REST bei unterschiedlichen Anfragenkomplexitäten

Um zu untersuchen, wie sich GraphQL und REST in Bezug auf die Latenz bei verschiedenen Anfragekomplexitäten verhalten, ist zunächst darauf einzugehen, welche von den APIs genutzten Faktoren oder Spezifikationen sich auf die Latenz auswirken. Bei der Bereitstellung von Daten setzt REST auf HTTP-Endpunkte, die nativ HTTP-Caching unterstützen, wodurch Ressourcen in einem Cache zwischengespeichert werden können, um unnötige Datenübertragungen sowie Serveranfragen zu vermeiden und somit die Zugriffszeiten zu verringern. Bei GraphQL wird dies nativ nicht unterstützt, wodurch wiederkehrende Anfragen nicht gecacht werden, sondern jeweils vom Server bearbeitet werden müssen, was zu höheren Zugriffszeiten führt. [20]

Bei REST wird die Zerlegung von Systemen in eine Menge verknüpfter Ressourcen mit einem bestimmten Granularitätsgrad gefördert, was zu Abwägungen zwischen Wiederverwendbarkeit und Leistung führt, die in der allgemeinen Software-Service-Architektur weitverbreitet sind. Weniger granulare und kohäsivere Services werden bevorzugt, weil sie lose Kopplung und hohe Wiederverwendbarkeit fördern. Dies kann jedoch zu Client-Server-Interaktionen führen, bei denen mehrere aufeinanderfolgende Anfragen notwendig sind, um die benötigten Daten aus dem Ressourcengraphen abzurufen. Dieses Phänomen ist als ‚Underfetching‘ oder ‚n+1-Problem‘ bekannt und tritt bei REST auf der Seite des Clients auf. Dieser muss dementsprechend weitere Anfragen schicken, bis die benötigten Daten vollständig bei ihm verfügbar sind. [13] [23]

Bei GraphQL kann es ebenso zu einem n+1-Problem kommen, wobei dieses jedoch nicht auf der Clientseite auftritt, sondern beim Server im Rahmen der Verarbeitung der Anfrage. Der GraphQL-Server muss mehrere Anfragen an die Datenbank schicken, um die benötigten Daten zu erhalten und, an den Client auszuliefern. [8]

Hierfür bietet GraphQL einen sogenannten DataLoader, der die zur Bearbeitung eines Requests benötigten Anfragen bündelt und als eine einzelne, optimierte, Datenbankabfrage ausführt. [14]

Zudem spielt bei der Latenz einer API die Anfragekomplexität eine entscheidende Rolle. In Abbildung 3.1 sind vergleichend die Ausführungszeiten vier unterschiedlicher API-Abfragen dargestellt, die sowohl mit REST als auch mit GraphQL auf den öffentlich zugänglichen GitHub-REST- und GraphQL-APIs durchgeführt wurden. Die Performance wurde hierbei in Millisekunden gemessen und gibt Aufschluss darüber, wie sich beide Technologien je nach Art der Anfrage verhalten.

Query	REST	GraphQL
Query 1	171.16	176.96
Query 2	627.00	606.34
Query 3	225.44	144.88
Query 4	338.16	388.46

Query 1: GET/user

Query 2: POST /repos/:owner/:repo/issues/:issue_number/comments

Query 3: GET/repos/:owner/:repo/issues/:issue_number

Query 4: GET/repos/:owner/:repo/stargazers

Abbildung 3.1: Latenz bei GraphQL vs. REST [20]

Die erste Abfrage (GET/user) zeigt, dass sich die Latenz zwischen REST und GraphQL nicht signifikant unterscheidet: Für diese Anfrage benötigt REST 171,16 Millisekunde, während GraphQL mit 176,96 Millisekunden nur geringfügig langsamer ist. Dies lässt darauf schließen, dass die Ergebnisse bei einfachen Anfragen ohne komplexe Datenstruktur als nahezu identisch bezeichnet werden können. Die zweite Abfrage (POST /repos/:owner/:repo/issues/:issue_number/comments), eine Schreiboperation, zeigt ein ähnliches Ergebnis, wobei GraphQL mit 606,34 Millisekunden leicht schneller arbeitet als REST mit 627 Millisekunden. Weil der Unterschied gering ist, deutet dies darauf hin, dass Schreiboperationen in beiden Technologien ähnlich effizient verarbeitet werden. Eine deutliche Differenz ergibt sich bei der dritten Abfrage (GET/repos/:owner/:repo/issues/:issue_number), wofür REST 225,44 Millisekunden benötigt, während sich GraphQL mit nur 144,88 Millisekunden als deutlich schneller erweist. Dies demonstriert die Überlegenheit von GraphQL bei komplexeren Datenanforderungen. Weil GraphQL in der Lage ist, mehrere Datenpunkte in einem einzelnen Aufruf zu bündeln, reduziert es die Anzahl der API-Aufrufe und arbeitet so effizienter. Die vierte Abfrage (GET/repos/:owner/:repo/stargazers) zeigt ein gegensätzliches Bild: Hier ist REST mit 338,16 Millisekunden schneller als GraphQL, das 388,46 Millisekunden benötigt. Dies liegt daran, dass die Abfrage keine komplexe Aggregation von Daten erfordert und der Overhead von GraphQL die Performance negativ beeinflusst. Somit kann festgehalten werden, dass REST in einem Szenario positivere Ergebnisse aufwies als GraphQL, in einem Szenario das Gegenteil der Fall war und beide Technologien in zwei Szenarien ähnliche Resultate erzielten. [20]

Weitere Studien zeigen, dass GraphQL bei einfachen Abfragen, die nur einen Endpunkt nutzen, etwa 0,02-mal schneller als REST arbeitet. [23]

Bei komplexeren Anfragen, die vier Endpunkte umfassen und 1000 Ergebnistupel liefern, verarbeitet eine GraphQL-API die Daten bis zu 16-mal schneller als eine REST-API.[12]

Anspruchsvollere Anfragen mit fünf oder mehr Endpunkten werden von GraphQL bis zu 187-mal schneller erfüllt.[21]

Bei steigender Komplexität stellt sich jedoch bei einer Menge von 100 000 Ergebnistupeln heraus, dass eine GraphQL-API in diesem Fall 0,36-[12] bis 2,5-mal langsamer arbeitet als eine vergleichbare REST-API [1].

3.2 Latenz von REST- und GraphQL-APIs bei Graph- und relationalen Datenbanken

Weil APIs eine Schnittstelle zwischen einer Datenbank und der Anwendung darstellen, die die Daten aus der Datenbank konsumieren soll, ist die Latenz einer API zwingend von der Bearbeitungszeit einer Anfrage innerhalb der Datenbank abhängig. Hierbei nutzen verschiedene Datenbanktypen jeweilige Methoden, um die angefragten Daten aus der Datenbank bereitzustellen. In dieser Arbeit wird durch die Forschungsfrage ein besonderer Schwerpunkt auf die Verarbeitung anhand der relationalen Algebra sowie der Graphentheorie gelegt. Diese Methoden bieten bei der Verwendung in Anwendungsszenarien Vorteile, führen aber zu Nachteilen hinsichtlich der Effizienz und Zeitersparnis bei der Anfragenbearbeitung. Hierbei zeigt sich bei relationalen Datenbanken, dass diese bei steigender Anzahl an gespeicherten Daten zunehmend langsamere Performance bieten. Wie in Abbildung 3.2 jedoch zu sehen ist, stieg die Menge der im Internet verarbeiteten Daten seit 2010 stetig an; die Prognosen bis ins Jahr 2028 deuten auf einen Trend zu erheblich mehr Daten. Graphdatenbanken können mit solch einem Wachstum effektiver umgehen, weil durch die Nutzung Traversal-basierter Anfragen, die für diese Art von Abfragen optimiert sind, die Menge der Daten innerhalb der Datenbank eine untergeordnete Rolle spielt. [9] [19]




Abbildung 3.2: Datenmenge weltweit [5]

Einen weiteren Faktor, der die Performance einer Datenbank beeinflusst, beschreibt die Verbundenheit, also die Relation, der Daten. Abbildung 3.3 zeigt, wie sich diese im Verlauf veränderte. Hierbei ist deutlich zu sehen, dass Daten stetig eine größere Verzweigung zueinander aufweisen.

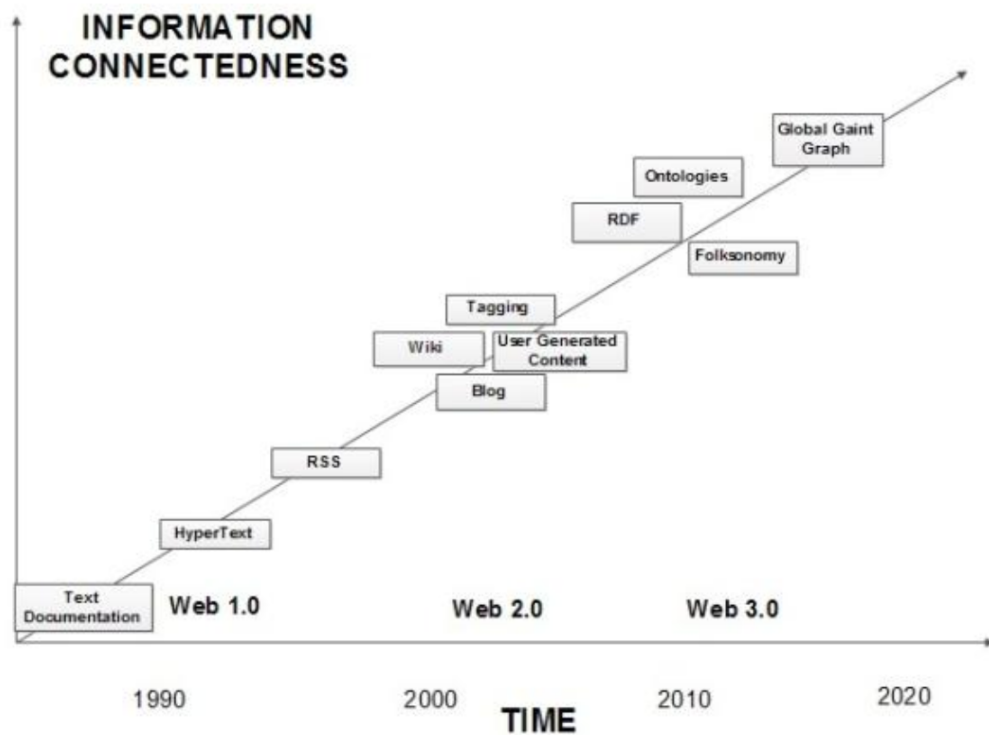


Abbildung 3.3: Informationsverbundenheit [19]

Eine Graphdatenbank kann mit diesem hohen Grad an Verzweigung durch die Verwendung der Graphentheorie und Traversierung performant umgehen, während bei relationalen Datenbanken dieser hohe Grad der Relationen eine Performanceeinbuße bewirkt. Weil bei der Verbindung der Daten die Relationen zwischen den Tabellen durch Joins realisiert werden und diese komplexer zu berechnen sind, steigt mit zunehmender Anzahl der Relationen die Zeit, welche die Datenbank benötigt, um mithilfe der Schlüssel und mehrerer Tabellen die Beziehung zwischen den Dateneinträgen zu konstruieren. [9] [16]

Die Universität von Mississippi führte ein Experiment durch, um die Latenzunterschiede zwischen einer relationalen MySQL- und einer Graphdatenbank (Neo4j) zu untersuchen. Dabei wurden sieben Szenarien simuliert, deren Ergebnisse in den Abbildungen 3.4 und 3.5 dokumentiert sind. In der ersten Spalte der Tabellen wird die Konfiguration der Datenbank dargestellt, wobei die Zahl die Menge der Nodes oder Tupel in der Datenbank angibt, gefolgt von einem Datentyp, der beschreibt, welche Art von Daten bei der Erstellung der Datenbank zufällig verwendet wurde. Die Ergebnisse beider Datenbanken sind in Abbildung 3.4 dargestellt, wobei die Abfragen I1 und I2 unterschiedliche Szenarien repräsentieren: Abfrage I1 selektiert alle Nodes, deren Payload einem bestimmten Wert entspricht, während I2 die Nodes zählt, deren Payload kleiner ist als ein gegebener Wert. Beide Szenarien nutzen den Datentyp Integer, um die Daten anzufordern. Anhand der experimentellen Daten wird deutlich, dass die relationale MySQL-Datenbank im Vergleich zur Graphdatenbank Neo4j in jedem getesteten Fall eine deutlich geringere Latenz aufweist. [22]

Database	Rel I1	Neo I1	Rel I2	Neo I2
1000int	0.3	33.0	0.0	40.6
5000int	0.4	24.8	0.4	27.5
10000int	0.8	33.1	0.6	34.8
100000int	4.6	33.1	7.0	43.9

Abbildung 3.4: Ergebnisse der Abfragen durch Integer in Millisekunden [22]

Abbildung 3.5 zeigt Abfragen auf, bei denen anhand eines Strings selektiert wurde, wobei die zweite Zeile angibt, welche Länge der String hatte, auf dessen Basis die Selektion vorgenommen wurde. Hierbei wird die Menge der Nodes gezählt, die den String enthalten. Die Ergebnisse weichen deutlich von den vorherigen Resultaten ab, bei denen mithilfe eines Integer selektiert wurde: Durch die Verwendung eines Strings übertrifft die relationale Datenbank die Graphdatenbank lediglich im ersten Szenario; in den komplexeren Fällen weist die Letztere klare Vorteile auf und ist bei anspruchsvolleren Anfragen in der Spitze um den Faktor 167 schneller. [22]

Database	Rel	Neo	Rel	Neo	Rel	Neo	Rel	Neo	Rel	Neo
	d=4	d=4	d=5	d=5	d=6	d=6	d=7	d=7	d=8	d=8
1000char8k	26.6	35.3	15.0	41.6	6.4	41.6	11.1	41.6	15.6	36.3
5000char8k	135.4	41.6	131.6	41.8	112.5	36.5	126.0	33.0	91.9	41.6
10000char8k	301.6	38.4	269.0	41.5	257.8	41.5	263.1	42.6	249.9	41.5
100000char8k	3132.4	41.5	3224.1	41.5	3099.1	42.6	3077.4	41.8	2834.4	36.4
1000char32k	59.5	41.5	41.6	42.6	30.9	41.5	31.9	41.4	31.9	35.4
5000char32k	253.4	42.3	242.9	41.5	229.4	35.3	188.5	38.5	152.0	41.5
10000char32k	458.4	36.3	468.8	41.6	468.3	41.6	382.1	41.5	298.8	36.3
100000char32k	3911.3	41.4	4859.1	33.3	6234.8	37.3	4703.3	41.5	2769.6	41.5

Abbildung 3.5: Ergebnisse Abfragen durch Character in Millisekunden [22]

Zusammenfassend lässt sich feststellen, dass relationale Datenbanken bei der Selektion von Daten anhand eines Integer deutlich schnellere Ergebnisse liefern. Bei der Abfrage von Daten anhand eines Strings zeigt sich zunächst, dass relationale Datenbanken bei kleinen Datenmengen effektiver performen, mit zunehmender Datenmenge wird jedoch die Graphdatenbank zunehmend effizienter und übertrifft schließlich die Performance der relationalen Datenbank deutlich.

4 Datenmodellierung

Um für das empirische Experiment eine Datenbasis zu schaffen, benötigt es ein Datenmodell. Hierbei soll ein möglichst realistisches und flexibles Modell genutzt werden, das zudem Verzweigungen aufweisen sollte, um verschiedene Anfragekomplexität abbilden zu können. Ein geeignetes Beispiel hierfür bietet ein Projektmanagementtool, das in diesem Szenario als Grundlage dient (vgl. Abb. 4.1). Dieses Tool besteht aus drei Klassen, die über drei Beziehungen miteinander verbunden sind. Die Klasse `Person` modelliert einen Menschen mit den Attributen `Firstname`, `Lastname` sowie `E-Mail` und steht mit der Klasse `Project` in einer `n:n`-Beziehung, wodurch mehrere `Project` Objekte einer `Person` zugeordnet werden können, aber auch mehrere `Person` Objekte an einem `Project` arbeiten können. In der Klasse `Project` werden nur der `Title` und das `Date` gespeichert, an dem das `Project` erstellt wurde. Ein `Project` steht in einer `1:n`-Beziehung zur Klasse `Issue`, wodurch einem `Issue` nur ein `Project` zugeordnet werden, ein `Project` aber mehrere `Issue` Objekte beinhalten kann. Hierbei speichert `Issue` Daten wie den `Title`, das `Date` an dem das `Issue` erstellt wurde, den `State` und die `StateReason`. Weiter besitzt `Issue` eine `n:n`-Beziehung zu `Person`, wodurch ein `Issue` von mehreren `Person` Objekten bearbeitet werden und eine `Person` an mehreren `Issue` Objekten tätig sein kann.

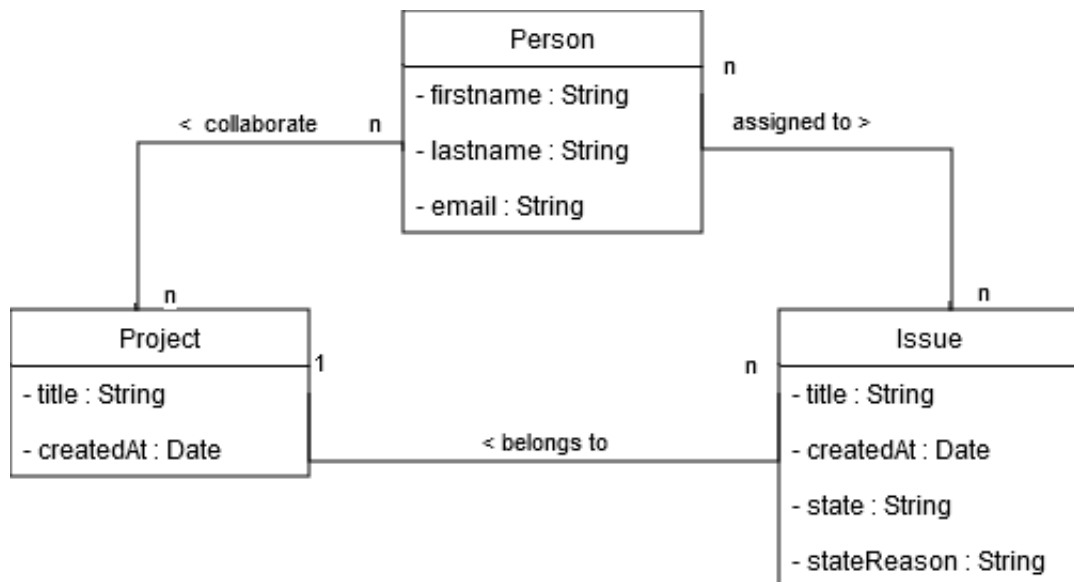


Abbildung 4.1: Klassendiagramm

5 Systemdesign

Innerhalb dieses Abschnitts werden die konkret gewählten Technologien für die Entwicklung eines Systems beschrieben, das für Latenztests verwendet werden kann.

5.1 Datenbankdesign

Für die Durchführung des Experiments wurden zwei Datenbanktypen verwendet, die nachfolgend mit ihrer spezifischen Konfiguration beschrieben werden.

5.1.1 Relationales Datenbankdesign




Abbildung 5.1: Datenbankdiagramm

Für die Erstellung einer relationalen Datenbank aus dem gegebenen Datenmodell (Abb. 4.1) wurde dieses wie in Abb. 5.1 zu sehen angepasst, um die Beziehung zwischen `Person` und `Project` sowie `Person` und `Issue` abzubilden. Somit ergeben sich für die relationale Datenbank fünf Tabellen, die in einer PostgreSQL-Datenbank realisiert werden. Dabei wird PostgreSQL verwendet, weil es ein leistungsfähiges, objekt-relationales Open-Source-Datenbanksystem bietet. Die Datenbank wurde mit den in Abbildung 5.2 bis 5.6 beispielhaft dargestellten Beispieldaten befüllt, wobei 500 000 `Person`- sowie `Project`- und `Issue`-Objekte in die Datenbank eingefügt wurden. Durch die Verwendung von Zwischentabellen, wie `Person_Issue` und `Person_Project`, enthält die relationale Datenbank 2,5 Mio. Tupel mit einem Speicherbedarf von 215 MB.

pid	firstname	lastname	email
1	Cecilla	Beningfield	cbeningfield9@wp.com

Abbildung 5.2: Tupel der Tabelle ‚Person‘

pid	iid
1	4894

Abbildung 5.3: Tupel der Tabelle ‚Person_Issue‘

iid	title	createdat	state	statereason	prid
1	Dabfeed	2023-06-10 00:00:00	Open	Assigned	586

Abbildung 5.4: Tupel der Tabelle ‚Issue‘

pid	prid
1	714

Abbildung 5.5: Tupel der Tabelle ‚Person_Project‘

prid	title	createdat
1	Asoka	2022-02-17 00:00:00

Abbildung 5.6: Tupel der Tabelle ‚Project‘

5.1.2 Graphdatenbankdesign

Die Erstellung einer Graphdatenbank erfordert keine definierten Tabellen, weil sie die Daten schemafrei speichert. Die Kanten werden bei der Erstellung entsprechend den Objekten benannt, was ebenso auf die Beziehungen zwischen den Knoten zutrifft. Als Graphdatenbank wurde auf Neo4j als eine der am weitesten verbreiteten Graphdatenbanken zurückgegriffen, die eine hohe Benutzerfreundlichkeit bietet. Abbildung 5.7 bietet eine Demonstration einer Beziehung zwischen jeweils einem Knoten. Die Kanten sind als gerichtete Kanten abgebildet, wobei `Person` zwei ausgehende Kanten, `Project` zwei eingehende und `Issue` jeweils sowohl eine eingehende als auch eine ausgehende Kante aufweist. Wie in der relationalen Datenbank wurden auch in der Graphdatenbank 500 000 Knoten pro Objekt erstellt. Hierbei waren jedoch keine Zwischentabellen zur Darstellung von Beziehungen nötig, wodurch in der Datenbank 1,5 Mio. Knoten vorliegen, die durch 2,01 Mio. Kanten verbunden sind. Hieraus ergibt sich eine Gesamtgröße von 197 MB.




Abbildung 5.7: Graphdiagramm

5.2 Schnittstellendesign

5.2.1 REST

Bei REST wird für jedes Testszenario ein separater Endpunkt benötigt, wobei sechs Endpunkte mit unterschiedlicher Komplexität entworfen wurden.

- **HEAD api/resource** wird verwendet, um einen Head-Request zur Bestimmung der Latenz der API durchzuführen..
- Durch **GET api/issues?counter=x&?joins=y** kann die Menge der Ergebnistupel (x) und die Anzahl der auf der Datenbank durchgeführten Joins (y) bei der Anfrage bestimmt werden, wobei die in Abbildung 5.8 dargestellte Antwort erwartet wird.

```
{
  "iid": 1,
  "title": "Pixope",
  "createdAt": "2024-07-23 00:00:00",
  "state": "Closed"
  "stateReason": "Cancelled"
},
[...]
```

Abbildung 5.8: ‚GET api/issues?counter=x&?joins=y‘-Response

- **GET api/persons/:pid** : Dieser Endpunkt ermöglicht das Abrufen einer bestimmten Person anhand ihrer ID, wobei die API ein JSON-Objekt zurückliefert, dass die Person mit den Attributen `Firstname`, `Lastname` und `E-Mail` beschreibt. (Abb. 5.9)

```
{
  "pid": 10,
  "firstname": "Cecilla",
  "lastname": "Beningfield",
  "email": "cbeningfield9@wp.com"
}
```

Abbildung 5.9: ‚GET api/persons/:pid‘-Response

- Mit dem Endpunkt **GET api/persons** können alle in der Datenbank gespeicherten Person- Objekte abgerufen werden, wobei die Antwort 5000 Project-Objekte im JSON-Format umfasst. (Abb. 5.10)

```
[
  {
    "pid": 1,
    "firstname": "Ruby",
    "lastname": "Burchatt",
    "email": "rburchatt0@msn.com"
  },
  [...]
  {
    "pid": 5000,
    "firstname": "Murdoch",
    "lastname": "Simonitto",
    "email": "msimonittorr@google.ca"
  }
]
```

Abbildung 5.10: ‚GET api/persons‘-Response

- Der Endpunkt **GET api/persons/:pid/projects/issue** erhöht die Komplexität, weil hier nicht nur auf ein einzelnes Objekt zugegriffen wird. Stattdessen erfordert die Abfrage zur Bearbeitung mehrere Objekte, die miteinander in Abhängigkeit stehen. Die Antwort umfasst alle Issue-Objekte, die in Project-Objekten vorhanden sind, in denen eine Person mitwirkt. (Abb. 5.11)

```
[
  {
    "iid": 1,
    "title": "Pixope",
    "createdAt": "2024-07-23 00:00:00",
    "state": "Closed"
    "stateReason": "Cancelled"
  },
  {
    "iid": 2876,
    "title": "Zoomlounge",
    "createdAt": "2020-08-26 00:00:00",
    "state": "Open"
    "stateReason": "Bug"
  },
]
```

Abbildung 5.11: ‚GET api/persons/:pid/projects/issue‘-Response

- Der Endpunkt **POST api/persons/:pid/projects/:pid/issues** ermöglicht das Erstellen eines neuen Issue in der Datenbank, um nicht nur Abfragen, sondern auch das Hinzufügen von Daten zu testen. Im Body der Anfrage wird ein Issue-Objekt im JSON-Format übergeben. (Abb. 5.12)

```
{
  "title": "test",
  "createdAt": "2023-02-21T00:00:00",
  "state": "Open",
  "stateReason": "Bug"
}
```

Abbildung 5.12: ‚POST api/persons/:pid/projects/:pid/issues‘-Body

Die Antwort enthält das erstellte Issue, das eine gültige ID sowie Verknüpfungen zu dem zugehörigen Project und der Person umfassen. (Abb. 5.13)

```
{
  "iid": 5207,
  "title": "test",
  "createdAt": "2023-02-21T00:00:00",
  "state": "Open",
  "stateReason": "Bug",
  "project": {
    "prid": 12,
    "title": "Y-find",
    "createdAt": "2021-01-10T00:00:00"
  },
  "assignee": {
    "pid": 1,
    "firstname": "Ruby",
    "lastname": "Burchatt",
    "email": "rburchatt0@msn.com"
  },
}
```

Abbildung 5.13: ‚POST api/persons/:pid/projects/:prid/issues‘-Response

5.2.2 GraphQL

Hinsichtlich der Art der Anfragen unterscheidet sich GraphQL stark von REST, denn es wird nur über den Endpunkt `POST api/graphql` angesprochen, worüber sowohl Querys als auch Mutations abgedeckt werden. Die Anfragen werden im Body mithilfe der GraphQL-Query-Language definiert, die JSON ähnelt. Die in 5.2.1 definierten REST-Endpunkte wurden in GraphQL nachgebildet, sodass sie dieselbe Antwort liefern. Für einen HEAD-Request bietet GraphQL nativ jedoch keine Lösung, weshalb in GraphQL APIs der HEAD-Request identisch wie in den REST-APIs implementiert wurde. Der parametrisierte Endpunkt aus der REST-API wurde in GraphQL entsprechend der Darstellung in Abb. 5.14 umgesetzt, wobei bei Counter Werte zwischen 0 und 1,5 Mio sowie bei Joins Werte zwischen 0 und 3 möglich sind.

```
query{
  issuesCount(counter: 10, joins: 1){
    iid
    title
    createdAt
    state
    stateReason
  }
}
```

Abbildung 5.14: GraphQL-Query GET `api/issues?counter=x&?joins=y`

Die in Abbildung 5.15 dargestellte Query ist dem REST-Endpunkt `GET api/persons/:pid` äquivalent, wobei ebenfalls eine ID übergeben wird. Allerdings können die in der Antwort enthaltenen Felder explizit gewählt werden. In diesem Beispiel wurden `PID`, `Firstname`, `Lastname` sowie die E-Mail genutzt, um dieselbe Antwort wie beim REST-Endpunkt zu erhalten.

```
query{
  person(id : 10){
    pid
    firstname
    lastname
    email
  }
}
```

Abbildung 5.15: GraphQL-Query-Äquivalent zu GET `api/persons/:pid`

Der REST-Endpunkt `GET api/persons` wird von der GraphQL-Query in Abbildung 5.16 repräsentiert, wobei dieselben Felder wie in der vorherigen Abfrage selektiert werden. Jedoch wird hierbei die Query `persons` angesprochen, wodurch alle `Person` Objekte der Datenbank abgerufen werden.

```
query {  
  persons {  
    pid  
    firstname  
    lastname  
    email  
  }  
}
```

Abbildung 5.16: GraphQL-Query-Äquivalent zu `GET api/persons`

Abbildung 5.17 zeigt die GraphQL-Query, die dem REST-Endpunkt `GET api/persons/:pid/projects/issue` entspricht. Hierbei werden die im Schema definierten Querys geschachtelt, um eine Abfrage zu erhalten, die die Abhängigkeiten zwischen den Objekten repräsentiert.

```
query{  
  person(id : 10){  
    projects{  
      issues{  
        iid  
        title  
        createdAt  
        state  
        stateReason  
      }  
    }  
  }  
}
```

Abbildung 5.17: GraphQL-Query-Äquivalent zu `GET api/persons/:pid/projects/issue`

Um den REST-Endpunkt `POST api/persons/:pid/projects/:prid/issues` nachzubilden wurde die in Abb. 5.18 dargestellte Mutation entwickelt. Hierbei wird ein Input-Objekt definiert, das die zur Erstellung des Issue benötigten Attribute beinhaltet. Danach kann selektiert werden, welche Felder in der Antwort enthalten sind.

```
mutation{
  createIssue(input:{
    title : „Bug in Login“
    createdAt : „2024-12-03T12:30:00“
    state : „Open“
    stateReason : „Error in Login“
    prid: 80
    pid: 10
  }){
    iid
    title
    state
    stateReason
    createdAt
    project{
      prid
      title
      createdAt
    }
    assignee{
      pid
      firstname
      lastname
      email
    }
  }
}
```

Abbildung 5.18: GraphQL-Query-Äquivalent zu `POST api/persons/:pid/projects/:prid/issues`

5.3 Testumgebung

Zur Ermittlung der Latenzzeiten wurden API-Abfragen durchgeführt, wobei die Antwortzeiten in Millisekunden protokolliert wurden. Dafür wurde eine Testumgebung mit zwei unterschiedlichen Endgeräten benötigt, um die Last auf mehrere Geräte zu verteilen. Die APIs liefen auf einem Server in Frankfurt, der mit vier Kernen, 24 GB Arbeitsspeicher, einer 1 Gbit-Internetverbindung und Ubuntu 22.04 als Betriebssystem ausgestattet ist.

Die Abfragen erfolgten von einem PC mit acht Kernen, 32 GB Arbeitsspeicher, einer 50 Mbit-Internetverbindung und Windows 10 als Betriebssystem, wobei die durchschnittliche Latenz (Ping) zwischen Server und PC 24 ms betrug. Weil ein Ping jedoch nur auf ISO-Schicht 3 agierte, wurde vor jedem Testdurchlauf mithilfe von HEAD-Requests, die in Kapitel 5.2.1 beschrieben wurden, eine Latenz zwischen den Endgeräten ermittelt, die alle ISO-Schichten durchlief. Um Schwankungen bei der Netzwerkauslastung und der Systembelastung zu minimieren, wurden pro Testszenario und API jeweils hundert Anfragen ausgeführt. Insgesamt ergibt dies bei vier APIs und 25 Testszenarien eine Datengrundlage von 10 000 Latenzzeiten.

6 Implementierung

Nachfolgend werden die Implementierung der verschiedenen APIs sowie die Grundprinzipien während der Implementierung beschrieben. Der Sourcecode der Implementierung ist unter der MIT Lizenz auf GitHub veröffentlicht. [10]

6.1 Grundprinzipien

Im Rahmen der Implementierung der Anwendung wurden Grundprinzipien beachtet, die sowohl die Qualität als auch die Erweiterbarkeit der Anwendungen sicherstellten, wobei die Wahl der verwendeten Technologien sowie die Anwendung bewährter Praktiken im Vordergrund stand. Als Basis für die Entwicklung wurde Java JDK 17.0.10 Corretto gewählt, weil diese als Long-Term-Support-Version eine stabile und sichere Grundlage für die Entwicklung darstellt. Amazon Corretto bietet eine optimierte JVM, wodurch alle Softwarebestandteile auf jeder Plattform mit einer zertifizierten JAVA Virtual Machine lauffähig sind. Ergänzt wurde JDK durch Spring Boot Version 3.3.4, eine weit verbreitete Plattform für die Entwicklung von Webanwendungen und Microservices, die eine schnelle und einfache Konfiguration von Anwendungen ermöglicht sowie den Entwicklungsprozess durch das Automatisieren häufig auftretender Aufgaben vereinfacht, etwa der Konfiguration von Servern und Datenbankverbindungen. Als zentrales Konzept während der Implementierung diente die Verwendung von Dependency-Injection (DI). Diese Technik gewährleistet, dass die Abhängigkeiten zwischen den einzelnen Komponenten der Anwendung nicht hartkodiert sind, sondern zur Laufzeit durch den DI-Container von Spring injiziert werden. Dabei fördert DI die Entkopplung von Komponenten, was die Testbarkeit, Flexibilität und Wartbarkeit des Codes fördert. Weil der Code durch DI in unabhängige, umfangreich getestete Module unterteilt wird, lässt er sich leicht erweitern und an geänderte Anforderungen anpassen. Zudem trägt DI zur Lesbarkeit des Codes bei, weil Abhängigkeiten nicht explizit an anderen Stellen generiert werden müssen. Die Implementierung der Anwendung erfolgte weiter unter der Berücksichtigung von Best Practices, die die Qualität des Codes sicherstellen und eine effiziente, langfristige Wartung ermöglichen. Einen wesentlichen Aspekt bildete hierbei die Modularität der Lösung, wobei die Anwendung so strukturiert wurde, dass jede Komponente eine klare, abgegrenzte Verantwortung übernahm. Dies unterstützte nicht nur die Nachvollziehbarkeit des Codes, sondern erleichterte auch das Testen und die Erweiterung von Funktionalitäten. Bestehende Komponenten konnten so problemlos durch neue ersetzt oder erweitert werden, ohne die gesamte Anwendung zu beeinträchtigen.

6.2 Post-REST

In dieser Arbeit steht ‚PostREST‘ für die PostgreSQL- REST-API, die eine Schnittstelle für den Zugriff auf eine PostgreSQL-Datenbank über HTTP-Anfragen bietet und mehrere Endpunkte implementiert, die in Abschnitt 5.2.1 der Arbeit definiert wurden und dafür verantwortlich sind, bestimmte Anfragen zu bearbeiten sowie entsprechende Antworten zurückzugeben. Als zentrale Komponente, die die korrekte Verarbeitung der Endpunkte sicherstellt, dient die Controller-Klasse (vgl. Abb. 6.1), worin die Endpunkte integriert sind, wobei jeder Endpunkt mit seinen spezifischen Pfadvariablen und den Rückgabewerten versehen ist. Die Controller-Klasse übernimmt die Ausführung der richtigen Methoden, wenn eine Anfrage an einen bestimmten Endpunkt gestellt wird. Daneben beschreibt der Postrest-Controller die konkrete Implementierung des Controllers, der die Geschäftslogik verarbeitet und den DBService aufruft, der das Interface IDBService implementiert, das wiederum die notwendigen Methoden für den Abruf von Daten aus den zugrunde liegenden Datenbanken definiert. Diese Methoden kapseln die Logik für den Datenbankzugriff und sind so gestaltet, dass sie von der Controller-Klasse verwendet werden können, um die korrekten Informationen zu erhalten. Die Kommunikation zwischen den verschiedenen Schichten der Anwendung erfolgt durch DI. Das bedeutet, dass die verschiedenen Komponenten nicht direkt in der Controller-Klasse erzeugt, sondern von außen in die Klasse injiziert werden, was in diesem Fall auf die Repositorys der verschiedenen Entitäten zutrifft. Diese Repositorys sind verantwortlich für den direkten Datenbankzugriff und beinhalten die notwendigen Methoden sowie SQL-Abfragen zum Abrufen und Verwalten der Daten in der Datenbank. Nachdem die Daten erfolgreich aus der Datenbank abgefragt wurden, werden sie durch die Hierarchie der Anwendung weitergegeben, wobei der PostrestController sicherstellt, dass die abgerufenen Daten ins gewünschte Format für die API-Antwort umgewandelt werden. Dies entspricht in diesem Fall dem JSON-Format, das dem Nutzer der API als Antwort übermittelt wird. Diese Antwort enthält die über die API angeforderten Informationen des Nutzers.

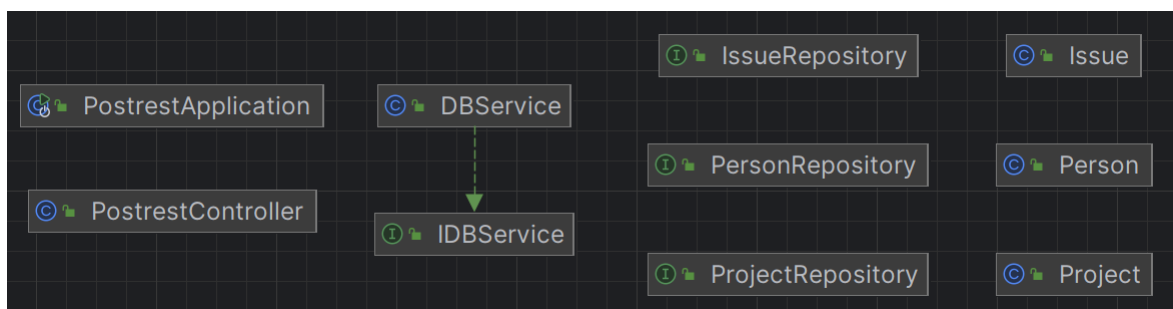


Abbildung 6.1: PostREST-Java-Klassen

6.3 Post-Graph

Bei PostGraph handelt es sich um eine GraphQL-API, die mit einer PostgreSQL-Datenbank verbunden ist, wobei das Schema, das die Arbeitsweise der API beschreibt, wie bei GraphQL üblich, in der Datei `schema.graphqls` definiert wird. In dieser Datei sind die verschiedenen Datentypen sowie die möglichen Querys und Mutationen beschrieben, die zur Abfrage und Bearbeitung der Daten verwendet werden können. In den folgenden Abbildungen sind Beispiele für einen Typ, verschiedene Querys und eine Mutation entsprechend ihrer Definition in der `schema.graphqls`-Datei dargestellt:

```
type Issue{
  iid : ID!
  title : String
  createdAt : String
  state : String
  stateReason : String
}
```

Abbildung 6.2: Typ aus der `schema.graphqls`-Datei

```
type Query{
  persons: [Person]
  person(id:ID!): Person
  projects: [Project]
  project(id:ID!) : Project
  issues : [Issue]
  issue(id: String): Issue
}
```

Abbildung 6.3: Query aus der `schema.graphqls`-Datei

```
type Mutation {
  createIssue(input: IssueInput): Issue
}
```

Abbildung 6.4: Mutation aus der `schema.graphqls`-Datei

Als zentrale Komponente für die Verarbeitung von Anfragen dient die Java-Klasse Query (vgl. Abb. 6.5), in der Methoden implementiert werden, die die Bearbeitung der Anfragen gemäß den Strukturen in der schema.graphqls-Datei ermöglichen. Diese Methoden greifen auf die Repositorys der Modellklassen zu, um Datenbankoperationen durchzuführen, wobei die Repositorys die erforderlichen Methoden und Logiken enthalten, um Daten in der PostgreSQL-Datenbank zu lesen oder zu ändern. Als wesentliches Merkmal von GraphQL gilt der Einsatz von Resolvern, die Felder verarbeiten, die auf Daten aus anderen Quellen oder Datenbanken basieren. Resolver stellen sicher, dass die relevanten Daten korrekt abgerufen und in der gewünschten Struktur zurückgegeben werden. Die Repositorys werden in die benötigten Klassen injiziert, sodass sie nicht direkt innerhalb der Anwendung erstellt werden müssen. Nach erfolgreicher Bearbeitung einer Anfrage liefert die GraphQL-API die Daten im vorgegebenen GraphQL-Format an den Nutzer zurück, was eine flexible und leistungsfähige Schnittstelle zur Abfrage und Manipulation der Daten in der zugrunde liegenden PostgreSQL-Datenbank gewährleistet.

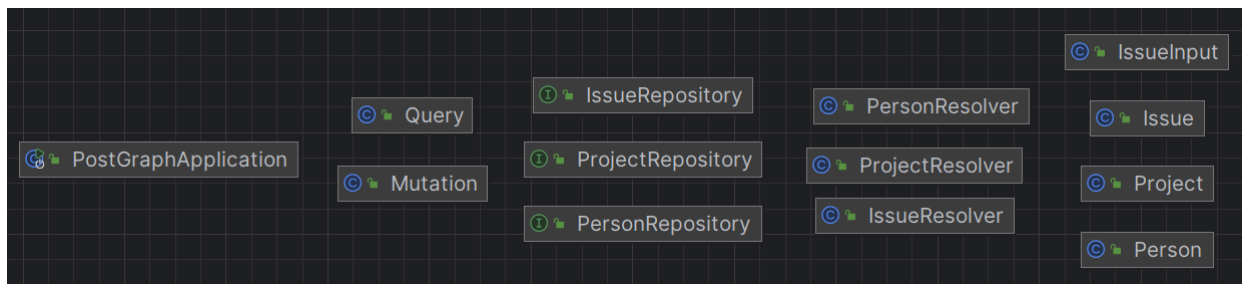


Abbildung 6.5: PostGraph-Java-Klassen

6.4 Neo4REST

Neo4REST beschreibt eine REST-API, die den Zugriff auf eine Neo4j-Datenbank ermöglicht. Analog zur Struktur von PostREST bietet Neo4REST mehrere Endpunkte, die zur Bearbeitung spezifischer Anfragen und zur Rückgabe der entsprechenden Antworten dienen; Details dieser Endpunkte sind in Abschnitt 5.2.2 definiert. Die Verarbeitung der Endpunkte wird durch die zentrale Controller-Klasse sichergestellt (vgl. Abb. 6.7), in der wie bei PostREST die spezifischen Pfadvariablen, Parameter und Rückgabewerte der Endpunkte definiert sind. Durch die Controller-Klasse werden die passenden Methoden aufgerufen, sobald eine Anfrage an einen der Endpunkte gestellt wird, wobei der Neo4RestController die Geschäftslogik übernimmt und datenbankbezogene Aufgaben an den DBService delegiert, der das Interface IDBService implementiert. Dieses Interface definiert die für den Zugriff auf die Neo4j-Datenbank erforderlichen Methoden, wobei die Umsetzung der konkreten Abfragen über Repositorys erfolgt, die für die Durchführung der Cypher-Abfragen zuständig sind. Diese Repositorys abstrahieren den Datenbankzugriff und bieten wiederverwendbare Methoden, um auf die in Neo4j gespeicherten Daten zuzugreifen oder sie zu ändern. Wie

bei PostREST werden die in der Datenbank abgefragten Informationen, durch die Schichten der Anwendung weitergeleitet und im Controller ins JSON-Format umgewandelt, bevor sie als API-Antwort zurückgegeben werden. So stellt Neo4REST sicher, dass der Nutzer die angeforderten Informationen oder den Status einer Operation im passenden Format erhält.

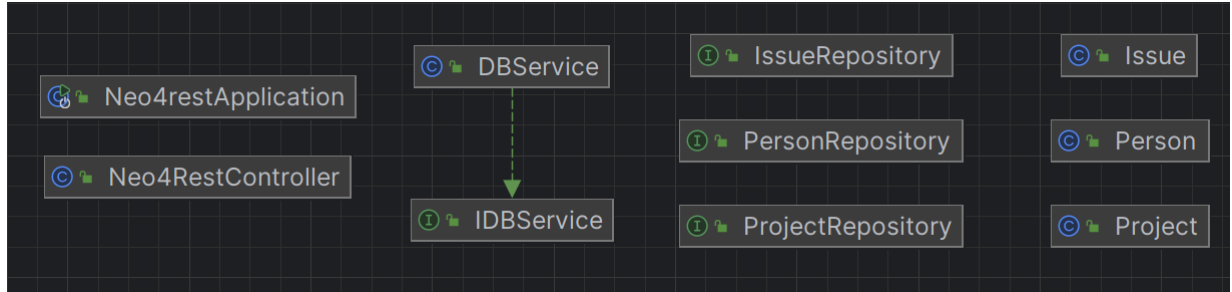


Abbildung 6.6: Neo4REST-Java-Klassen

6.5 Neo4Graph

Die Neo4Graph-API stellt eine GraphQL-API dar, die mit einer Neo4j-Datenbank verbunden ist, wobei das bereits in Bezug auf die PostGraph-API beschriebene Schema bei Neo4Graph auf ähnliche Weise implementiert wird: Wie bei PostGraph kommen Cypher-Abfragen zum Einsatz, um mit der Neo4j-Datenbank zu interagieren. Die Methoden nutzen die Neo4j-Clientbibliothek, um Knoten und Kanten effizient zu durchsuchen sowie Datenbankoperationen durchzuführen. Ein weiteres gemeinsames Merkmal beider APIs stellt der Einsatz von Resolvem dar, die bei Neo4Graph ebenfalls zur Bearbeitung von Feldern verwendet werden, die auf Beziehungen oder aggregierten Daten im Graphen basieren. Resolver sorgen dafür, dass die benötigten Daten korrekt abgerufen und in der gewünschten Struktur zurückgegeben werden. Nach der Bearbeitung einer Anfrage liefert die GraphQL-API die Daten im standardisierten GraphQL-Format an den Nutzer, was eine konsistente und leistungsfähige Schnittstelle zur Abfrage sowie Bearbeitung der Daten in der Neo4j-Datenbank sicherstellt.

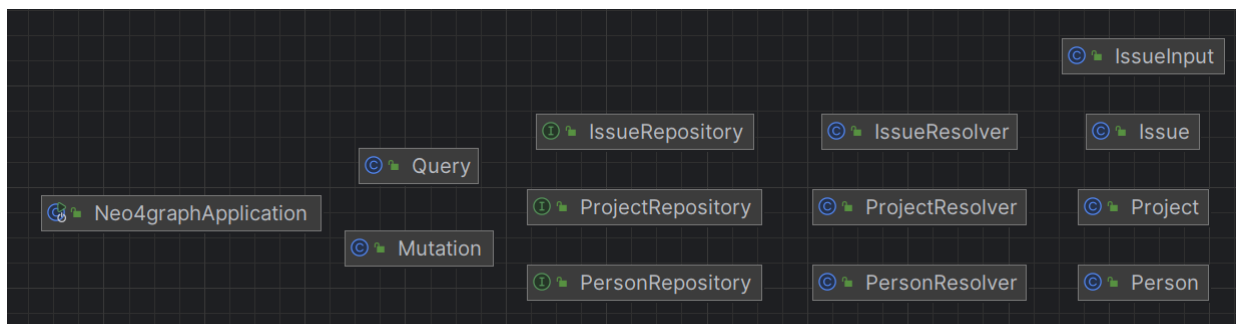


Abbildung 6.7: Neo4Graph-Java-Klassen

6.6 API-Response-Test

Für die Ermöglichung von API-Anfragen von einem entfernten System aus wurde eine Anwendung entwickelt, die für jeden Endpunkt eine Methode enthält (vgl. Abb. 6.8), die jeweils hundert Abfragen in einer Schleife ausführt. Falls für eine Abfrage eine ID erforderlich ist, wird diese mithilfe der Klasse Random aus `java.util.Random` generiert. Die Abfragen für den parametrisierten Endpunkt werden mit den Joins von 0 bis 3 und den Ergebnistupeln 1, 100, 1000, 10 000 sowie 100 000 durchgeführt, wobei die Abfragezeit ermittelt wird, indem die aktuelle Systemzeit in Millisekunden unmittelbar vor der Ausführung der Abfrage erfasst und von der Zeit nach Abschluss der Abfrage abgezogen wird.




Abbildung 6.8: Java Klassen Neo4Graph

7 Ergebnisse

Im Nachfolgenden werden die Ergebnisse der Latenztests der in Kapitel 6 eingeführten APIs dargestellt, wobei die konkreten Zahlen, auf denen die Grafiken beruhen, im Kapitel Appendix zu finden sind.

Zunächst wurde, wie in Abbildung 7.1 zu sehen, mittels HEAD- Request ermittelt, ob die API verfügbar war sowie welche Latenz zwischen Client und Server ohne Ausführung einer Datenabfrage entstand. Hierbei wurde beobachtet, dass die Latenzen von PostGraph und Neo4Graph dicht beieinander lagen, wobei die Latenz REST-basierter APIs in diesem Experiment deutlich variierte.




Abbildung 7.1: HEAD /api/resource

Daraufhin wurden die Latenzen des parametrisierten API-Endpunktes ermittelt. In den Abbildungen 7.2 bis 7.5 wurden diese Ergebnisse in einem Koordinatensystem dargestellt, wobei die x-Achse die Menge der angeforderten Tupel repräsentiert; aufgrund der hohen Menge der Ergebnistupel wurde diese Achse logarithmisch abgebildet. Auf der z-Achse ist die Latenz in Millisekunden zu sehen. Die verschiedenen Graphen innerhalb der Abbildungen beschreiben die Menge der Joins bei relationalen Datenbanken oder Kanten bei Graphdatenbanken. Rot (Kreis) steht hierbei für null, Blau (Quadrat) für eins und Orange (Diamant) für zwei. Bei PostREST (vgl. Abb. 7.2) steigt demnach die Latenz mit der Menge der Ergebnistupel exponentiell an, wobei zu erkennen ist, dass bei einer Anzahl von 100 000 Ergebnistupeln die Menge der Joins deutlich Einfluss auf die Latenz nimmt: Hierbei ist eine Anfrage mit weniger Joins (rot) mit 426,5 Millisekunden deutlich performanter als mit mehreren Joins (orange), die 492,5 Millisekunden benötigt. Bei niedrigerer Tupelzahl wirken sich Joins nicht bzw. nur in geringem Maß auf die Latenz der Anfrage aus.




Abbildung 7.2: PostREST parametrisierte Abfragen

PostGraph zeigt in Abbildung 7.3 ähnliche Resultate, jedoch mit einer deutlich höheren Latenz bei einer Anfragengröße von 100 000 Tupeln. Die GraphQL-API ist hier mit 1831 Millisekunden um einen Faktor von 3,7 langsamer als die REST-API, die auf derselben Datenbank basiert.




Abbildung 7.3: PostGraph parametrisierte Abfragen

Bei Verwendung einer Neo4j-Datenbank in Kombination mit einer REST-API (vgl. Abb. 7.4) fällt auf, dass die Anfragen mit geringer Tupelzahl eine ähnliche Latenz aufweisen, während bei höherer Tupelzahl die Anfragedauer deutlich höher liegt als bei einer relationalen Datenbank. Hierbei ist jedoch erkennbar, dass Anfragen mit mehreren Kanten schneller bearbeitet werden; so benötigt eine Anfrage ohne das Nutzen einer Kante 1673 Millisekunden. Wenn nun die Komplexität erhöht und für die Anfrage zwei Kanten verwendet werden, benötigt diese lediglich 1371 Millisekunden.




Abbildung 7.4: Neo4REST parametrisierte Abfragen

Bei gleicher Datenbasis und Nutzung einer GraphQL-API (vgl. Abb. 7.5) fällt auf, dass erneut die Anfragedauer bei hoher Tupelzahl deutlich über der einer REST-API liegt. Ebenfalls ist hier zu beobachten, dass komplexere Anfragen schneller bearbeitet werden als weniger komplexe.




Abbildung 7.5: Neo4Graph parametrisierte Abfragen

Wie in Abbildung 7.6 zu sehen ist, weist die PostgreSQL REST-API eine höhere Latenzzeit als die GraphQL-PostgreSQL auf. Dies deutet darauf hin, dass die GraphQL-API bei der Abfrage eines spezifischen `Person` Objekts, anhand der `Person-ID` in Kombination mit einer relationalen Datenbank effizientere Abfragen und eine höhere Performance bei der Verarbeitung bietet. Ähnliches zeigt sich bei einer Neo4j-Datenbank: Auch hier besitzt die Neo4j-GraphQL-API niedrigere Latenzzeiten als die REST-API. Allerdings liegen die Latenzen bei Neo4j minimal höher als beim relationalen Pendant, was darauf hindeutet, dass PostgreSQL bei dieser Anfrage eine performantere Verarbeitung von Abfragen ermöglicht. Zusammenfassend ist für diese Anfrage festzuhalten, dass GraphQL in Kombination sowohl mit einer relationalen als auch mit einer Graphdatenbank eine niedrigere Latenz aufweist, worüber hinaus sich Postgres bei dieser Anfrage insgesamt als minimal performanter erweist als Neo4j.




Abbildung 7.6: GET /api/persons/:pid

In Abbildung 7.7 sind die Latenzen für die komplexere Anfrage dargestellt, die 5000 `Person`-Objekte aus der Datenbank zurückliefert. GraphQL zeigt hierbei sowohl bei der relationalen als auch bei der Graphdatenbank im Median eine niedrigere Latenz, womit REST in beiden Fällen der weniger performanten API entspricht.




Abbildung 7.7: GET /api/persons

Wenn die Anfragekomplexität steigt, wodurch sich die Abhängigkeit zwischen den Objekten in der Datenbank erhöht, ist deutlich zu sehen, dass die Streuung bei der Postgres-GraphQL-API höher ausfällt als bei allen anderen APIs (vgl. Abb.7.8), wobei der Median jedoch wesentlich niedriger liegt. Die Neo4j REST-API befindet sich in diesem Fall deutlich über allen anderen APIs, gefolgt von der PostgreSQL-REST-API. Beide GraphQL-APIs weisen erneut eine wesentlich niedrigere Latenz auf.




Abbildung 7.8: GET /api/persons/:pid/projects/issues

Bei der Speicherung in eine Datenbank sind andere Resultate zu erkennen: Wie in Abbildung 7.9 veranschaulicht, erweist sich hierbei die Postgres-REST-API als diejenige mit der geringsten Latenz, dicht gefolgt von der Postgres-GraphQL-API. Eine deutlich höhere Latenz ist bei den Neo4j-APIs zu erkennen, wobei allerdings die GraphQL-API die performantere darstellt.




Abbildung 7.9: POST /api/persons/:pid/projects/:prid/issues

8 Diskussion

In diesem Kapitel werden die aus dem Experiment gewonnenen Erkenntnisse mit den Ergebnissen der Literaturanalyse verglichen, um die empirischen Resultate zu überprüfen.

Im Rahmen des Experiments wurde untersucht, wie sich die Latenzzeiten von REST- und GraphQL-APIs unter verschiedenen Anfragenkomplexitäten unterscheiden, wobei die Ergebnisse zeigten, dass REST bei Anfragen mit hoher Datenlast (100 000 Ergebnistupel) unabhängig von der zugrunde liegenden Datenbank einen deutlichen Vorteil gegenüber GraphQL aufweist. Dies deckt sich mit der Literatur, die GraphQL bei solchen Szenarien als etwa 2,5-mal langsamer beschreibt [1].

Für einfache Anfragen wurde in der Literatur ein Geschwindigkeitsfaktor von 0,02 zugunsten von GraphQL genannt [23], der im Experiment jedoch mehrfach übertroffen wurde. Besonders bei parametrisierten Anfragen ohne Joins zeigte GraphQL eine bis zu 1,9-mal höhere Performance als REST. Dies wurde auch bei einem Endpunkt beobachtet, der realen Anwendungen entspricht (z. B. `GET /api/persons/:pid`).

Komplexere Anfragen mehrerer Tabellen oder Nodes innerhalb einer Datenbank (z. B. `GET /api/persons/:pid/projects/issues`) zeigten ebenfalls einen deutlichen Vorteil für GraphQL, wobei diese Überlegenheit auch in der Literatur beschrieben wird [20]. Demnach kann GraphQL Anfragen, die eine Aggregation oder den Zugriff auf verschachtelte Daten erfordern, effizienter verarbeiten, was seine Stärke bei solchen Szenarien unterstreicht.

Bei der Erstellung von Daten werden in der Literatur keine signifikanten Effizienzunterschiede zwischen den beiden Ansätzen festgestellt [20]. Diese Beobachtung wurde im Experiment bestätigt: Der Unterschied in der Median-Latenzzeit betrug maximal 7 Millisekunden.

Ein weiterer untersuchter Aspekt betraf die Auswirkung der Datenbank, konkret einer relationalen oder Graphdatenbank, auf die zuvor genannten APIs. Dabei zeigen die parametrisierten Anfragen, dass sich die Graph- und die relationale Datenbank bei der Abfragedauer kaum unterschieden; lediglich die Abfrage nach 100 000 Tupeln rief bei der Graphdatenbank eine deutlich erhöhte Latenz hervor, und dies unabhängig von der API. Dies weicht von der Literatur ab [22]; die Erwartung war, dass die Abfragedauer nahezu gleichblieb. Graphdatenbanken sind für Abfragen mit hoher Komplexität optimiert, jedoch nicht unbedingt für Bulk-Extraktionen, worüber hinaus sie potenziell mehr Overhead aufweisen und mehr Speicher- sowie CPU-Operationen benötigen.

Bei einer Abfrage, die mehr Beziehungsevaluationen benötigt (`GET /api/persons/:pid/projects/issues`), war zu erkennen, dass die Graphentheorie hier einen deutlichen Vorteil aufweist: Die GraphQL-API bearbeitete die Anfrage in Kombination mit einer Graphdatenbank dreimal schneller als eine REST-API, die mit einer Graphdatenbank operierte. Aufseiten der relationalen Datenbank war ebenfalls ein Unterschied zu erkennen, der aber mit einem Fak-

tor von 1,6 deutlich geringer ausfiel.

Bei der Erstellung von Daten auf der Datenbank wurde deutlich sichtbar, dass eine Graphdatenbank erheblich länger für die Erstellung benötigt. Dies ist damit zu begründen, dass bei dieser die Tupel lediglich in der Datenbank abgelegt werden, ohne eine Beziehung zueinander herzustellen. Dies erfolgt direkt bei der Erstellung der Daten, wodurch die Graphdatenbank mehr Rechenzeit für das Erstellen und die Verbindung der Knoten benötigt. [4]

9 Ausblick

Im Rahmen dieser Arbeit wurden GraphQL und REST in Kombination mit relationalen sowie Graphdatenbanken analysiert, wobei zahlreiche Ansatzpunkte für weiterführende Untersuchungen identifiziert wurden, die sowohl technische als auch konzeptionelle Aspekte betreffen.

Ein erstes Potenzial für zukünftige Arbeiten liegt in der Betrachtung der Implementierung von APIs unter Verwendung unterschiedlicher Programmiersprachen. Die in dieser Arbeit analysierten Implementierungen konzentrierten sich auf spezifische Technologien, was die Frage offenlässt, ob andere Programmiersprachen, insbesondere solche mit unterschiedlichen Paradigmen (z. B. funktional oder objektorientiert), ebenfalls einen Einfluss auf die Latenz oder andere Leistungsparameter der APIs haben. Eine vergleichende Analyse könnte hierzu wertvolle Erkenntnisse liefern.

Im Bereich der Datenbanken wäre es ebenfalls lohnend, die Untersuchung auf weitere Datenbanktypen auszudehnen. Besonders dokumentenbasierte NoSQL-Datenbanken wie MongoDB oder Couchbase bieten Potenzial für ergänzende Analysen, weil sie aufgrund ihrer strukturellen Unterschiede gegenüber relationalen und graphbasierten Datenbanken relevante Alternativen darstellen. Solche Untersuchungen könnten Aufschluss darüber geben, inwiefern dokumentenbasierte Datenbanken spezifische Vorteile oder Herausforderungen für den Einsatz mit REST oder GraphQL bieten.

Darüber hinaus könnte der Einsatz eines komplexeren Datenmodells bedeutende Erkenntnisse liefern. In dieser Arbeit wurde ein moderates Datenmodell genutzt, das nur eine begrenzte Anzahl an Relationen aufwies. Eine Erweiterung des Modells, beispielsweise durch eine höhere Anzahl von Tabellen oder Knoten sowie komplexere Verknüpfungen zwischen diesen, würde die Belastung der Datenbank und der API erhöhen. Solche Szenarien könnten dazu beitragen, die Skalierbarkeit und Effizienz der untersuchten Technologien unter realistischeren Bedingungen zu bewerten.

Zusammenfassend bietet diese Arbeit eine Grundlage für weiterführende Analysen und stellt mehrere Ansätze für zukünftige Forschungen bereit, die sowohl auf theoretischer als auch auf praktischer Ebene die Relevanz und Einsatzmöglichkeiten von GraphQL sowie REST vertiefen könnten.

10 Fazit

Die vorliegende Arbeit untersuchte die Performance von REST- und GraphQL-APIs in Kombination mit relationalen sowie graphbasierten Datenbanken und analysierte deren Vor- und Nachteile unter verschiedenen Anfragekomplexitäten, wobei zwei zentrale Forschungsfragen bearbeitet wurden.

FF1: Wie unterscheiden sich GraphQL und REST hinsichtlich der Latenzzeit bei unterschiedlichen Anfragenkomplexitäten? Bei komplexeren Anfragen zeigt GraphQL deutliche Vorteile, weil es in der Lage ist, mehrere Datenpunkte in einer einzigen Abfrage zu bündeln, was die Anzahl der API-Aufrufe reduziert. Dies führt in Szenarien mit mehreren abhängigen Datenpunkten zu geringeren Latenzzeiten im Vergleich zu REST. Dieses hingegen erweist sich bei einfachen Anfragen als effizienter, insbesondere aufgrund der nativen Unterstützung von HTTP-Caching, das sich wiederholende Anfragen deutlich beschleunigt. Jedoch gleicht GraphQL diesen Vorteil aus und zeigt auch bei einfachen Abfragen schnellere Antwortzeiten. Lediglich bei Anfragen, die eine große Tupelzahl zurückliefern, ergeben sich bei REST deutlich schnellere Antwortzeiten. Gemäß den Ergebnissen hängt die Wahl der API-Technologie stark von der Komplexität der Anfragen ab: Während sich REST für Bulk-Abfragen anbietet, zeigt sich GraphQL bei einfachen und hierarchischen Abfragen überlegen.

FF2: Wie beeinflussen Graph- und relationale Datenbanken die Latenz von REST- und GraphQL-APIs? Die Wahl der zugrunde liegenden Datenbank hat ebenfalls einen signifikanten Einfluss auf die Latenz: Relationale Datenbanken erweisen sich bei der Verarbeitung einfacher und strukturierter Daten als effizient, insbesondere bei Abfragen mit geringen Datenmengen. Mit zunehmender Komplexität und stark vernetzten Daten stoßen sie jedoch an ihre Grenzen. Graphdatenbanken wie Neo4j zeigen hier ihre Stärke, indem sie Traversal-Mechanismen nutzen, um Beziehungen zwischen Daten effizienter zu verarbeiten. Dies führt bei komplexen Szenarien zu einer deutlichen Reduzierung der Latenz, insbesondere in Kombination mit GraphQL. Hingegen profitiert REST nur begrenzt von graphbasierten Datenbanken, weil zusätzliche Konvertierungsaufwände für die Datenstruktur entstehen.

Auf dieser Basis gelangt die vorliegende Arbeit zu dem Schluss, dass die Kombination aus API-Architektur und Datenbanktechnologie genau auf die spezifischen Anforderungen eines Anwendungsfalls abgestimmt werden muss. Während REST und relationale Datenbanken eine bewährte Lösung für klassische Anwendungen darstellen, bieten GraphQL und Graphdatenbanken eine leistungsfähige Alternative, die zudem stark vernetzte Anfragen performanter bearbeiten kann.

Literaturverzeichnis

- [1] Tobias Andersson and Håkan Reinholdsson. Rest api vs graphql - a literature and experimental study. 2021. <https://researchportal.hkr.se/ws/portalfiles/portal/40132480/FULLTEXT01.pdf>.
- [2] J. A. Bondy and U. S. R. Murty. *GRAPH THEORY WITH APPLICATIONS*. Elsevier Science Publishing Co., Inc., 52 Vanderbilt Avenue, New York, N.Y. 10017, 1976. ISBN: 0-444-19451-7 <https://www.iro.umontreal.ca/~hahn/IFT3545/GTWA.pdf>.
- [3] E.F. Codd. Relational model of data for large shared data banks. *IBM Research Laboratory, San Jose, California*, 1970. <https://doi.org/10.1145/362384.362685>.
- [4] Calin Constantinov, Mihai L Mocanu, and Cosmin M Poteras. Running complex queries on a graph database: A performance evaluation of neo4j. *Annals of the University of Craiova*, 12(1):38–44, 2015.
- [5] IDC; Statista estimates. Volume of data/information created, captured, copied, and consumed worldwide from 2010 to 2023, with forecasts from 2024 to 2028, 2024. <https://www.statista.com/statistics/871513/worldwide-data-created/>.
- [6] Roy T. Fielding. Architectural styles and the design of network-based software architectures. 2000. <https://ics.uci.edu/~fielding/pubs/dissertation/top.htm>.
- [7] Cornelia Györödi, Alexandra Ștefan, Robert Györödi, and Livia Bandici. A comparative study of databases with different methods of internal data management. *International Journal of Advanced Computer Science and Applications (IJACSA) Vol. 7, No. 4.,* 2016. <https://dx.doi.org/10.14569/IJACSA.2016.070433>.
- [8] Olaf Hartig and Jorge Pérez. Semantics and complexity of graphql. *WWW 2018, April 23-27, 2018, Lyon, France*, 2018. <https://doi.org/10.1145/3178876.3186014>.
- [9] Mohammad A. Hassan. Relational and nosql databases: The appropriate database model choice. In *2021 22nd International Arab Conference on Information Technology (ACIT)*, pages 1–6, 2021. <https://doi.org/10.1109/ACIT53391.2021.9677042>.
- [10] Robin Hefner. Bachelorthesis. <https://github.com/D4rkm4n215/Bachelorthesis>.

- [11] Daniel Jacobson, Greg Brail, and Dan Woods. *APIs: A Strategy Guide*. O'Reilly Medi, Sebastopol, CA, 2012. ISBN: 978-1-449-30892-6.
- [12] Mafalda Isabel Ferreira Landeiro. Analysis of graphql performance: a case study. 2019. https://recipp.ipp.pt/bitstream/10400.22/15946/1/DM_MalfaldaLandeiro_2019_MEI.pdf.
- [13] Suresh Kumar Mukhiyaa, Fazle Rabbi, Violet Ka I Pun, Adrian Rutlea, and Yngve Lamo. A graphql approach to healthcare information exchange with hl7 fhir. *The 9th International Conference on Current and Future Trends of Information and Communication Technologies in Healthcare (ICTH 2019)*, 2019. <https://doi.org/10.1016/j.procs.2019.11.082>.
- [14] Didrik Nordström and Marcus Vilhelmsson. Graphql query performance comparison using mysql and mongodb: By conducting experiments with and without a dataloader, 2022. <https://urn.kb.se/resolve?urn=urn%3Anbn%3Ase%3Ahj%3Adiva-58563>.
- [15] Snehal Eknath Phule. Graph theory applications in database management. *International Journal of Scientific Research in Modern Science and Technology Volume 3*, 2024. <https://doi.org/10.59828/ijrmst.v3i3.190>.
- [16] Ian Robinson, Jim Webber, and Emil Eifrem. *Graph Databases*. O'Reilly Medi, Sebastopol, CA, 2015. ISBN: 978-1-491-93200-1.
- [17] Rahman Saidur. *Basic Graph Theory*. Springer, Cham, Switzerland, 2017. ISBN: 978-3-319-49474-6.
- [18] Thomas Studer. *Relationale Datenbanken*. Springer Vieweg, Berlin, Germany, 2019. ISBN: 978-3-662-58976-2.
- [19] Clarence J M Tauro, Aravindh S, and Shreeharsha A.B. Comparative study of the new generation, agile, scalable, high performance nosql databases. *International Journal of Computer Applications (0975 – 888) Volume 48– No.20*, 2012. <http://dx.doi.org/10.5120/7461-0336>.
- [20] Sri Lakshmi Vadlamani, Benjamin Emdon, Joshua Arts, and Olga Baysal. Can graphql replace rest? a study of their efficiency and viability. 2021. <https://ieeexplore.ieee.org/abstract/document/9474834>.
- [21] Milena Vesić and Nenad Kojić. N. comparative analysis of web application performance in case of using rest versus graphql. pages 17–24, 2020. https://www.itema-conference.com/wp-content/uploads/2021/03/0_Itema-2020-Conference-Proceedings_Draft.pdf#page=23.

- [22] Chad Vicknair, Michael Macias, Zhendong Zhao, Xiaofei Nan, Yixin Chen, and Dawn Wilkins. A comparison of a graph database and a relational database: a data provenance perspective. 2010. <https://doi.org/10.1145/1900008.1900067>.
- [23] Maximilian Vogel, Sebastian Weber, and Christian Zirpins. Experiences on migrating restful web services to graphql. *Springer Nature 2018*, 2018. https://doi.org/10.1007/978-3-319-91764-1_23.

Eidesstattliche Erklärung

Ich erkläre hiermit an Eides statt, dass ich die vorliegende Arbeit selbständig verfasst und dabei keine anderen als die angegebenen Hilfsmittel benutzt habe. Sämtliche Stellen der Arbeit, die im Wortlaut oder dem Sinn nach Publikationen oder Vorträgen anderer Autoren entnommen sind, habe ich als solche kenntlich gemacht. Die Arbeit wurde bisher weder gesamt noch in Teilen einer anderen Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Heilbronn, den 21. Januar 2025

(Nachname, Vorname)

Appendix

In diesem Anhang befinden sich die Werte der Grafiken, welche im Ergebnis vorgestellt wurden.

HEAD /api/resource

	PostREST	PostGraph	Neo4REST	Neo4Graph
Upper Whisker	59	54	63	54
Upper Quartile	55	53	58	53
Median	52	53	52	52
Lower Quartile	52	53	52	52
Lower Whisker	51	52	51	51

PostREST parametrisierte Abfragen

Tupel	Joins	ms
1	0	111
100	0	121
1000	0	135
10000	0	272
100000	0	426,5

Tupel	Joins	ms
1	1	111
100	1	122
1000	1	134
10000	1	271,5
100000	1	468

Tupel	Joins	ms
1	2	111
100	2	119,5
1000	2	146
10000	2	267
100000	2	492,5

PostGraph parametrisierte Abfragen

Tupel	Joins	ms
1	0	56
100	0	66
1000	0	87,5
10000	0	240,5
100000	0	1815,5

Tupel	Joins	ms
1	1	94
100	1	103
1000	1	129
10000	1	283,5
100000	1	1831,5

Tupel	Joins	ms
1	2	55
100	2	65
1000	2	91,5
10000	2	292
100000	2	1792,5

Neo4REST parametrisierte Abfragen

Tupel	Joins	ms
1	0	119
100	0	126
1000	0	147
10000	0	282
100000	0	1673

Tupel	Joins	ms
1	1	113,5
100	1	124
1000	1	143,5
10000	1	269
100000	1	1466

Tupel	Joins	ms
1	2	112
100	2	122
1000	2	145
10000	2	269
100000	2	1371

Neo4Graph parametrisierte Abfragen

Tupel	Joins	ms
1	0	58
100	0	70
1000	0	105,5
10000	0	391
100000	0	2726,5

Tupel	Joins	ms
1	1	59
100	1	70
1000	1	102,5
10000	1	330
100000	1	2484,5

Tupel	Joins	ms
1	2	57
100	2	69
1000	2	96
10000	2	317
100000	2	2396,5

GET /api/persons/:pid

	PostREST	PostGraph	Neo4REST	Neo4Graph
Upper Whisker	113	60	120	63
Upper Quartile	110	57	114	60
Median	109	56	113	59
Lower Quartile	108	55	110	58
Lower Whisker	106	54	108	57

GET /api/persons

	PostREST	PostGraph	Neo4REST	Neo4Graph
Upper Whisker	297	216	291	279
Upper Quartile	278	197	275	267
Median	268	190	266	261
Lower Quartile	265	181	259	254
Lower Whisker	250	165	245	241

GET /api/persons/:pid/projects/issues

	PostREST	PostGraph	Neo4REST	Neo4Graph
Upper Whisker	148	180	195	62
Upper Quartile	142	123	184	60
Median	139	88	178	59
Lower Quartile	137	85	176	58
Lower Whisker	135	83	173	57

POST /api/persons/:pid/projects/:prid/issues

	PostREST	PostGraph	Neo4REST	Neo4Graph
Upper Whisker	60	62	118	99
Upper Quartile	57	60	97	87
Median	56	58	89	82
Lower Quartile	55	57	83	78
Lower Whisker	54	55	77	73